



Αριστοτέλειο Πανεπιστήμιο Θεσσαλονίκης
Τμήμα Ηλεκτρολόγων Μηχανικών και Μηχανικών Υπολογιστών
Κατεύθυνση Ηλεκτρονικής και Υπολογιστών

Μια εισαγωγή στη Βαθιά Μάθηση για το Φυσικό Επίπεδο

Μπαρμπαγιάννος Βασίλειος, ΑΕΜ: 10685

Επιβλέποντες: Νέστορας Χατζηδιαμαντής, Αναπληρωτής Καθηγητής
Θράσος Οικονόμου, Υποψήφιος Διδάκτορας

Θεσσαλονίκη, Ιούνιος 2026

Περίληψη

Σε αυτή την εργασία αντιμετωπίζεται ένα σύστημα επικοινωνίας υλοποιημένο ως Autoencoder. Γίνεται προσπάθεια να βελτιστοποιηθούν ταυτόχρονα πομπός και δέκτης, δηλαδή από κοινού. Αυτή η ιδέα επεκτείνεται σε δίκτυα πολλαπλών πομπών και δεκτών (δίκτυα MIMO). Εισάγεται η έννοια των Radio Transformer Networks (RTNs) ως ένας τρόπος να συμπεριληφθεί η ειδική γνώση (expert domain knowledge) στο μοντέλο βαθιάς μάθησης. Τέλος, παρουσιάζεται η εφαρμογή συνελικτικών νευρωνικών δικτύων (Convolutional Neural Networks (CNNs)) σε IQ δείγματα για ταξινόμηση της διαμόρφωσης, η οποία παρουσιάζει επιδόσεις ανταγωνιστικές ως προς τις παραδοσιακές μεθόδους οι οποίες βασίζονται σε ειδικά χαρακτηριστικά (expert features).

Abstract

This thesis explores a communication system implemented as an end-to-end Autoencoder. The primary objective is the joint optimization of the transmitter and receiver. This concept is further extended to multi-user networks involving multiple transmitters and receivers (MIMO systems). Radio Transformer Networks (RTNs) are introduced as a framework to incorporate expert domain knowledge into the deep learning model. Finally, the application of Convolutional Neural Networks (CNNs) on raw IQ samples for modulation classification is presented, demonstrating performance competitive with traditional methods based on hand-crafted expert features.

Ευχαριστίες

Θέλω να εκφράσω την ειλικρινή μου ευγνωμοσύνη προς τον κύριο Νέστορα Χατζηδιαμαντή που με δέχτηκε για εκπόνηση διπλωματικής εργασίας καθώς και στον κύριο Θράσο Οικονόμου για την βοήθειά του καθόλη τη διάρκεια εκπόνησής της.

Ακόμη, ευχαριστώ τους κοντινούς μου ανθρώπους, οικογένεια και φίλους, που μου συμπαραστάθηκαν καθόλη τη διάρκεια των σπουδών μου.

Βασίλειος Μπαρμπαγιάννος

Θεσσαλονίκη, Ιούνιος 2026

Αφιέρωση

Στους γονείς μου, Γιώργο και Γιωργία.

Περιεχόμενα

Περίληψη	i
Abstract	ii
Ευχαριστίες	iii
1 Εισαγωγή	1
1.1 Διατύπωση Προβλήματος	1
1.2 Κίνητρο	2
1.3 Προκλήσεις του φυσικού επιπέδου	2
1.4 Δομή της εργασίας	3
2 Θεωρητικό Υπόβαθρο	5
2.1 Βασικές αρχές Βαθιάς Μάθησης	5
2.1.1 Νευρωνικά Δίκτυα	6
2.1.2 Αλγόριθμος SGD	7
2.1.3 Adam Optimizer	8
2.2 Συνελικτικά Νευρωνικά Δίκτυα	8

2.3	Η κατηγορία των νευρωνικών δικτύων που λέγονται Autoencoders	9
3	Επικοινωνιακά συστήματα end-to-end με Autoencoders	12
3.1	End-to-end αναπαράσταση με autoencoder	13
3.2	Αρχιτεκτονική και εκπαίδευση	15
3.2.1	Αρχιτεκτονική	15
3.2.2	Εκπαίδευση	16
3.3	Εκμάθηση αστερισμών σε κανάλι AWGN	17
3.4	Επίδραση των περιορισμών ισχύος	25
3.5	Σύγκριση απόδοσης: Autoencoder vs κλασικές μέθοδοι	37
3.5.1	Σύγκριση μεταξύ Autoencoders	37
3.5.2	Σύγκριση μεταξύ Autoencoder και Hamming	39
3.5.3	Περισσότερα κρυφά επίπεδα στο νευρωνικό του Autoencoder	42
3.5.4	Το πρόβλημα της τυχαίας στροφής φάσης	43
4	Συστήματα Πολλών Εισόδων - Πολλών Εξόδων	45
4.1	Δύο χρήστες σε AWGN κανάλι με παρεμβολές	45
4.2	Τρόπος επικοινωνίας	46
4.3	Αρχιτεκτονική του συστήματος	49
4.4	Η πρόκληση της εκπαίδευσης	50
4.5	Αστερισμοί στο επίπεδο	52
4.6	Επίδοση BLER	56

5	Radio Transformer Networks (RTNs)	59
5.1	Ενσωμάτωση ειδικής γνώσης	59
5.2	Αρχιτεκτονική RTN	60
5.3	Πρόβλημα ισοστάθμισης σε πολυδιαδρομικά κανάλια	60
5.4	Αποτελέσματα	64
6	Ταξινόμηση διαμόρφωσης με χρήση CNN	72
6.1	Το πρόβλημα	72
6.2	Το dataset RadioML 2016.10A	74
6.3	Αρχιτεκτονική του CNN νευρωνικού δικτύου	75
6.4	Δένδρα Απόφασης	76
6.5	Αποτελέσματα	77
6.5.1	Σύγκριση Ταξινομητών	77
6.5.2	Confusion Matrix	80
7	Συμπεράσματα και μελλοντική εργασία	83
7.1	Ανακεφαλαίωση επιδόσεων	83
7.2	Αξιοσημείωτα συμπεράσματα	85
7.3	Περιορισμοί και προτάσεις για περαιτέρω έρευνα	85
7.4	Επίλογος	86
	Βιβλιογραφία	86

Κατάλογος Πινάκων

3.1	Αποτελέσματα προσομοίωσης Monte Carlo ($N_{test} = 500.000$) για το σύστημα (2,2) χωρίς περιορισμό ισχύος.	20
3.2	Αποτελέσματα προσομοίωσης Monte Carlo ($N_{test} = 500.000$) για το σύστημα (2,4) χωρίς περιορισμό ισχύος.	23
3.3	Αποτελέσματα προσομοίωσης Monte Carlo ($N_{test} = 500.000$) για το σύστημα (2,2) με περιορισμό μέσης ισχύος.	26
3.4	Αποτελέσματα προσομοίωσης Monte Carlo ($N_{test} = 500.000$) για το σύστημα (2,4) με περιορισμό μέσης ισχύος.	29
3.5	Αποτελέσματα προσομοίωσης Monte Carlo ($N_{test} = 500.000$) για το σύστημα (2,2) με περιορισμό ισχύος ανά σύμβολο.	32
3.6	Αποτελέσματα προσομοίωσης Monte Carlo ($N_{test} = 500.000$) για το σύστημα (2,4) με περιορισμό ισχύος ανά σύμβολο.	35
4.1	Παράμετροι εκπαίδευσης των autoencoders για την κατασκευή του σχήματος 4.7. .	57
6.1	Αρχιτεκτονική του CNN για ταξινόμηση διαμόρφωσης με 324.363 παραμέτρους. . .	76

Κατάλογος Σχημάτων

1.1	Αναπαράσταση ενός τηλεπικοινωνιακού συστήματος.	3
2.1	Αναπαράσταση ενός νευρωνικού δικτύου.	6
2.2	Τυπική αρχιτεκτονική ενός CNN [1].	9
2.3	Αναπαράσταση ενός autoencoder.	10
3.1	Αναπαράσταση ενός τηλεπικοινωνιακού συστήματος [2].	13
3.2	Αναπαράσταση απλής μορφής συστήματος επικοινωνίας.	14
3.3	Σύστημα επικοινωνίας υλοποιημένο ως autoencoder.	14
3.4	Εξέλιξη αστερισμού για σύστημα (2,2) χωρίς περιορισμό ισχύος.	19
3.5	BLER για σύστημα (2,2) χωρίς περιορισμό ισχύος.	21
3.6	Εξέλιξη αστερισμού για σύστημα (2,4) χωρίς περιορισμό ισχύος.	22
3.7	BLER για σύστημα (2,4) χωρίς περιορισμό ισχύος.	24
3.8	Εξέλιξη αστερισμού για σύστημα (2,2) με περιορισμό μέσης ισχύος.	25
3.9	BLER για σύστημα (2,2) με περιορισμό μέσης ισχύος.	27
3.10	Εξέλιξη αστερισμού για σύστημα (2,4) με περιορισμό μέσης ισχύος.	28
3.11	BLER για σύστημα (2,4) με περιορισμό μέσης ισχύος.	30

3.12	Εξέλιξη αστερισμού για σύστημα (2,2) με περιορισμό μέσης ισχύος ανά σύμβολο.	31
3.13	BLER για σύστημα (2,2) με περιορισμό μέσης ισχύος ανά σύμβολο.	33
3.14	Εξέλιξη αστερισμού για σύστημα (2,4) με περιορισμό μέσης ισχύος ανά σύμβολο.	34
3.15	BLER για σύστημα (2,4) με περιορισμό μέσης ισχύος ανά σύμβολο.	36
3.16	Σύγκριση BLER για Autoencoder(2,2) σε όλους τους περιορισμούς ισχύος.	37
3.17	Σύγκριση BLER για Autoencoder(2,4) σε όλους τους περιορισμούς ισχύος.	38
3.18	Σύγκριση BLER: Autoencoder(2,4) vs 16-QAM.	40
3.19	Σύγκριση BLER: Autoencoder(7,4) vs Hamming(7,4).	41
3.20	Σύγκριση BLER: Autoencoder(7,4) vs Hamming(7,4).	42
3.21	Σύγκριση BLER: Autoencoder(7,4) vs Hamming(7,4) σε στροφή φάσης [0,45] μοίρες (αριστερά) και σε [0,90] μοίρες (δεξιά).	43
4.1	Σύστημα με δύο ζευγάρια πομπού-δέκτη που μοιράζονται κοινό κανάλι.	49
4.2	Αστερισμός για το σύστημα δύο χρηστών με παραμέτρους (1,1).	52
4.3	Αστερισμός για το σύστημα δύο χρηστών με παραμέτρους (2,2).	53
4.4	Αστερισμός για το σύστημα δύο χρηστών με παραμέτρους (4,4).	54
4.5	Αστερισμός για το σύστημα δύο χρηστών με παραμέτρους (4,8).	55
4.6	Ανάλυση επίδοσης BLER: Χρήστης 1 εναντίον Χρήστη 2.	56
4.7	BLER vs E_b/N_0 για τον autoencoder και το $2^{2k/n}$ -QAM time-sharing για τις παραμέτρους $(n, k) = \{(1, 1), (2, 2), (4, 4), (4, 8)\}$	58
5.1	Δέκτης υλοποιημένος ως δίκτυο RTN.	60
5.2	Πολυδιαδρομικό κανάλι σε θάλασσα.	61

5.3	Πολυδιαδρομικό κανάλι σε αστικό περιβάλλον.	62
5.4	Κατανομή Rayleigh.	64
5.5	Αστερισμοί για τα σήματα $\mathbf{x}, \mathbf{y}, \bar{\mathbf{y}}$	65
5.6	Καμπύλες BLER που συγκρίνει την επίδοση των τριών διαφορετικών μεθόδων (στις 300 εποχές).	67
5.7	Καμπύλες BLER που συγκρίνει την επίδοση των τριών διαφορετικών μεθόδων (στις 600 εποχές).	68
5.8	Χάσμα επίδοσης σε μορφή ραβδογράμματος.	69
5.9	Training loss.	71
6.1	Σύγκριση απόδοσης ταξινομητών σε ωμά IQ δείγματα.	78
6.2	Σύγκριση απόδοσης ταξινομητών με εξαγωγή ειδικών χαρακτηριστικών.	79
6.3	Πίνακας Σύγχυσης του CNN (για $\text{SNR} = 10 \text{ dB}$).	81

Κεφάλαιο 1

Εισαγωγή

Οι επικοινωνίες (και κατ' επέκταση οι τηλεπικοινωνίες) αποτελούν μια ώριμη επιστημονική περιοχή. Αυτό σημαίνει ότι υπάρχουν ήδη μέθοδοι μοντελοποίησης του καναλιού, αντιστάθμισης ατελειών του υλικού (hardware) και σχεδίασης βέλτιστων μεθόδων ανίχνευσης που εγγυώνται την αξιόπιστη μεταφορά δεδομένων, δηλαδή την επικοινωνία με τα ελάχιστα δυνατά σφάλματα.

Ως εκ τούτου, ο πύχνης που πρέπει να περάσει η χρήση βαθιάς μάθησης είναι ιδιαίτερα υψηλός, προκειμένου να προσφέρει ανταγωνιστικά πλεονεκτήματα ως προς τις παραδοσιακές μεθόδους.

1.1 Διατύπωση Προβλήματος

Το σημείο ενδιαφέροντος είναι το φυσικό επίπεδο, δηλαδή το ίδιο το κανάλι του τηλεπικοινωνιακού συστήματος, στο οποίο λαμβάνει χώρα η μετάδοση του σήματος. Οι περισσότεροι παραδοσιακοί αλγόριθμοι επεξεργασίας σήματος είναι ώριμοι και βελτιστοποιημένοι, αλλά για γνωστά κανάλια. Τέτοια κανάλια έχουν γραμμικές και Γκαουσιανές ιδιότητες. Όμως ένα πραγματικό κανάλι έχει διάφορες ατέλειες και μη-γραμμικότητες (παραδείγματος χάρη μη γραμμικούς ενισχυτές ισχύος), στο οποίο μόνο προσεγγιστικά μπορούν να εφαρμοστούν οι παραπάνω αλγόριθμοι. Σε αυτό το πλαίσιο λοιπόν, ένα σύστημα επικοινωνιών με χρήση Autoencoders που δεν απαιτεί γνωστό μαθηματικό μοντέλο για το κανάλι, ίσως να μπορεί να βελτιστοποιηθεί καλύτερα υπό αυτές τις ατέλειες, δηλαδή

να μειώσει στο ελάχιστο δυνατό το σφάλμα κατά την επικοινωνία. Αυτό είναι και το πρόβλημα που φιλοδοξεί να μελετήσει και λύσει αυτή η εργασία με την υιοθέτηση βαθιάς μάθησης.

1.2 Κίνητρο


Η Βαθιά Μάθηση προσφέρει ποικιλία ωφελειών. Ήδη χρησιμοποιείται με ιδιαίτερη επιτυχία σε αμέτρητες εφαρμογές, όπως στην αναγνώριση εικόνας, στην επεξεργασία φυσικής γλώσσας, στην επεξεργασία σημάτων, στην βιοϊατρική κ.α.

Στις επικοινωνίες είναι ήδη γνωστό πως θα σχεδιαστεί ένα σήμα για αναγνώριση συμβόλου σε μια πλειάδα καναλιών (όπως το Additive White Gaussian Noise - AWGN κανάλι). Παρ' όλ' αυτά, δίνεται βαρύτητα στα οφέλη της βαθιάς μάθησης (στην παρούσα εργασία, τον autoencoder) για βελτίωση της απόδοσης σε περίπλοκα συστήματα, των οποίων η ακριβής μαθηματική μοντελοποίηση του καναλιού δεν είναι γνωστή.

Ακόμη, ένα σύστημα επικοινωνίας αποτελείται από έναν αριθμό από blocks (βλ. σχήμα 1.1): την κωδικοποίηση στο πομπό, τους κώδικες διόρθωσης σφαλμάτων, τη διαμόρφωση, τον digital-to-analog converter (DAC), κυκλώματα όπως φίλτρα και ενισχυτές, τη μετάδοση στο κανάλι και έπειτα τη μετατροπή αναλογικού σε ψηφιακό, την αποδιαμόρφωση και την αποκωδικοποίηση του δέκτη. Αντί να βελτιστοποιήσει ο τηλεπικοινωνιακός μηχανικός όλα αυτά τα ενδιάμεσα blocks ξεχωριστά, τοποθετεί έναν Autoencoder στη θέση τους, ο οποίος εκπαιδεύεται για να πετύχει **ταυτόχρονα και από κοινού** την βελτιστοποίηση πομπού και δέκτη. Τέλος, η αναπαράσταση ενός τηλεπικοινωνιακού συστήματος ως autoencoder αποτελεί και έναν νέο τρόπο σχεδίασης τηλεπικοινωνιακών συστημάτων.

1.3 Προκλήσεις του φυσικού επιπέδου

Στην εργασία αυτή θα μελετηθούν και ερευνηθούν οι εξής παθογένειες-προκλήσεις του φυσικού επιπέδου.



Σχήμα 1.1: Αναπαράσταση ενός τηλεπικοινωνιακού συστήματος.

- Μεταβαλλόμενα κανάλια: το κανάλι Rayleigh όπου το σήμα φτάνει με μεταβαλλόμενο πλάτος και φάση.
- Άγνωστη στροφής φάσης: πρόκληση που δυσκολεύει την αναγνώριση συμβόλου.

1.4 Δομή της εργασίας

Η υπόλοιπη διπλωματική εργασία χωρίζεται σε 6 κεφάλαια.

- Στο κεφάλαιο 2, αναφέρονται το θεωρητικό υπόβαθρο της βαθιάς μάθησης, των νευρωνικών δικτύων και της ειδικής κατηγορίας νευρωνικών δικτύων - τον autoencoder.
- Στο κεφάλαιο 3, γίνεται λόγος για την end-to-end αναπαράσταση του συστήματος επικοινωνίας ως autoencoder.
- Στο κεφάλαιο 4 επεκτείνεται αυτή η έννοια σε δίκτυα πολλαπλών πομπών-δεκτών τα οποία ανταγωνίζονται για τη χωρητικότητα του καναλιού.
- Στο κεφάλαιο 5, παρουσιάζονται τα δίκτυα Radio Transformer Networks ως ένας τρόπος να ενσωματωθεί η ειδική αποκτηθείσα γνώση στα νευρωνικά δίκτυα.

- Στο κεφάλαιο 6, χρησιμοποιούνται συνελικτικά νευρωνικά δίκτυα σε εργασίες ταξινόμησης διαμορφώσεων.
- Στο κεφάλαιο 7, εξάγονται τα συμπεράσματα και σημειώνονται προτάσεις για μελλοντική περαιτέρω έρευνα.

Κεφάλαιο 2

Θεωρητικό Υπόβαθρο

Σε αυτό το κεφάλαιο θεμελιώνονται θεωρητικά τα όσα θα ακολουθήσουν. Γίνεται αναφορά στον ορισμό της βαθιάς μάθησης και των νευρωνικών δικτύων, στον τρόπο εκπαίδευσής των, στον αλγόριθμο **Stochastic Gradient Descent (SGD)** και στον **Adam Optimizer**. Ακολουθεί η ανάλυση των **συνελικτικών νευρωνικών δικτύων** και τέλος η ειδική κατηγορία νευρωνικών δικτύων, η οποία είναι και η κύρια θεματολογία της εργασίας, οι **αυτοκωδικοποιητές (autoencoders)**.

2.1 Βασικές αρχές Βαθιάς Μάθησης

Η **Τεχνητή Νοημοσύνη** είναι όρος ομπρέλα για να περιγράψει τομείς όπως η Μηχανική Μάθηση, η Βαθιά Μάθηση, τα Μεγάλα Γλωσσικά Μοντέλα κ.α. Σκοπός της τεχνητής νοημοσύνης είναι να παράγει έξυπνες μηχανές, δηλαδή μηχανές που θα μπορούν να λύσουν ένα πρόβλημα χωρίς την βοήθεια ανθρώπου [3, κεφάλαιο 1]. Για παράδειγμα, η τεχνητή νοημοσύνη δύναται να καταστήσει έναν υπολογιστή ικανό να αναγνωρίσει αντικείμενα σε μια εικόνα. Ο υπολογιστής θα το κάνει μόνος του, χωρίς να χρειάζεται έναν άνθρωπο να τον βοηθήσει.

Όμως για να αποκτήσει ‘‘νοημοσύνη’’ ο υπολογιστής, πρέπει να **εκπαιδευτεί**. Παραδείγματος χάρη, πρέπει να εκπαιδευτεί σε πολλές εικόνες με σκύλους ώστε στο τέλος να μπορεί να αναγνω-

ρίσει μια εικόνα σκύλου, την οποία δεν είδε κατά τη διάρκεια της εκπαίδευσης. Λέμε τότε ότι ο υπολογιστής έμαθε να αναγνωρίζει σκύλους.


Ως **μάθηση** ορίζεται η διαδικασία βελτίωσης της επίδοσης ενός συστήματος σε μια συγκεκριμένη εργασία μετά από την παρατήρηση πολλών παραδειγμάτων [4, σελ. 17].

Όπως ειπώθηκε, για να μάθει ο υπολογιστής πρέπει πρώτα να εκπαιδευτεί. Η μάθηση είναι το αποτέλεσμα της εκπαίδευσης. Ο στόχος της μάθησης είναι η γενίκευση, δηλαδή η δυνατότητα παραγωγής σωστών εκτιμήσεων σχετικά με δεδομένα τα οποία βλέπει πρώτη φορά το σύστημα και όχι η απομνημόνευση [4, σελ. 19].

Η Μηχανική Μάθηση είναι ο τομέας της Τεχνητής Νοημοσύνης που ασχολείται με την ανάπτυξη αλγορίθμων μάθησης. Η Βαθιά Μάθηση είναι Μηχανική Μάθηση απλώς τα νευρωνικά δίκτυα έχουν περισσότερα επίπεδα, δηλαδή είναι βαθύτερα [5, κεφάλαιο 6].

2.1.1 Νευρωνικά Δίκτυα

Ο ορθότερος όρος για τα νευρωνικά δίκτυα είναι **τεχνητά νευρωνικά δίκτυα**, καθώς αποτελούν τεχνητές κατασκευές οι οποίες μιμούνται τη δομή και λειτουργία του βιολογικού εγκεφάλου. Ένα τυπικό νευρωνικό δίκτυο φαίνεται στο σχήμα 2.1.



Σχήμα 2.1: Αναπαράσταση ενός νευρωνικού δικτύου.

Αποτελείται από τον κόμβο εισόδου, στον οποίο μπαίνουν ως είσοδος τα δεδομένα $x_1, x_2, \dots, x_n$ και τα οποία πολλαπλασιάζονται με τα συναπτικά βάρη $w_1, w_2, \dots, w_n$. Στον κόμβο εισόδου μπαίνει

και το x_0 που πολλαπλασιάζεται με το bias w_0 . Κατόπιν όλα αυτά αθροίζονται και το αποτέλεσμα περνάει από τη συνάρτηση ενεργοποίησης για να δώσουν την έξοδο y [4, ενότητα 4.2], [6, κεφάλαιο 1]

$$y = f\left(\sum_{i=0}^N x_i w_i\right) \quad (2.1)$$

Αντικείμενο εκπαίδευσης αποτελούν τα βάρη w_i τα οποία ενημερώνονται με αλγορίθμους όπως ο Stochastic Gradient Descent.

2.1.2 Αλγόριθμος SGD

Ο αλγόριθμος της **στοχαστικής βαθμωτής καθόδου** (stochastic gradient descent) αποτελεί αλγόριθμο βελτιστοποίησης. Ενημερώνει σε κάθε επανάληψη τα βάρη. Έστω ότι ο στόχος είναι η ελαχιστοποίηση μιας συνάρτησης κόστους

$$f(\mathbf{w}) = \sum_{n=0}^N E_n(\mathbf{w}) \quad (2.2)$$

όπου $\mathbf{w}$ το διάνυσμα βαρών και $E_n(\mathbf{w})$ το κόστος που αντιστοιχεί στο n -στο δείγμα. Η κλίση της συνάρτησης f ως προς $\mathbf{w}$ είναι

$$\nabla_{\mathbf{w}} f = \sum_{n=1}^N \nabla_{\mathbf{w}} E_n \quad (2.3)$$

Τα δεδομένα χωρίζονται σε μικρές ομάδες, σε μικρά πακέτα (**batches**). Το κάθε batch περιέχει ένα δείγμα των δεδομένων, π.χ. 500 δείγματα από τα 10.000 συνολικά δεδομένα. Το B συμβολίζει τον αριθμό των δειγμάτων σε κάθε ομάδα (batch). Η i -στη ομάδα θα περιέχει τα δείγματα $\mathbf{x}_{(i-1)B+1}, \dots, \mathbf{x}_{iB}$. Το διάνυσμα $\mathbf{w}$ θα ενημερώνεται σύμφωνα με τη σχέση

$$\mathbf{w} \leftarrow \mathbf{w} - \beta \sum_{n=(i-1)B+1}^{iB} \nabla_{\mathbf{w}} E_n \quad (2.4)$$

Το β είναι το μέγεθος του βήματος ή αλλιώς ο **ρυθμός μάθησης** (learning rate). Αυτή η μέθοδος εκπαίδευσης ονομάζεται στοχαστική βαθμωτή κατάβαση (ή καθόδου) [7] και οδηγεί σε ταχύτερη σύγκλιση του διανύσματος των βαρών $\mathbf{w}$.

Για να εκπαιδευτεί ένα μοντέλο βαθιάς μάθησης απαιτεί δεδομένα. Συνήθως αυτά παρέχονται από **σύνολα δεδομένων** (datasets). Το νευρωνικό πρέπει να εκπαιδευτεί σε ένα πλήθος δεδομένων που καλείται **σύνολο εκπαίδευσης** (training set). Έπειτα θα αξιολογηθεί η απόδοσή του σε ένα **σύνολο ελέγχου** (test set), το οποίο ασφαλώς δεν θα έχει δει κατά τη διάρκεια της εκπαίδευσης, προκειμένου να διαπιστωθεί η ικανότητα μάθησης και γενίκευσης του νευρωνικού.

Συνεπώς το σύνολο δεδομένων χωρίζεται σε:


- Σύνολο εκπαίδευσης: σε αυτά τα δεδομένα εκπαιδεύεται το μοντέλο.
- Σύνολο ελέγχου: σε αυτά τα δεδομένα αξιολογείται το μοντέλο.

2.1.3 Adam Optimizer

Ο Adam Optimizer είναι μια τεχνική η οποία προσαρμόζει δυναμικά το learning rate κατά τη διάρκεια της εκπαίδευσης [8]. Αποφεύγει τις ταλαντώσεις και τα τοπικά ελάχιστα, βοηθώντας τη βελτιστοποίηση. Αποτελεί πολύ καλή επιλογή έναντι του αλγορίθμου SGD [9]. Στην εργασία χρησιμοποιείται ως εντολή Python.

2.2 Συνελικτικά Νευρωνικά Δίκτυα

Τα συνελικτικά νευρωνικά δίκτυα (Convolutional Neural Networks - CNNs) είναι πολυστρωματικά νευρωνικά δίκτυα ιδανικά για αναγνώριση εικόνας. Είναι βαθιά δίκτυα και αποτελούνται από εναλλασσόμενα στρώματα συνέλιξης και υποδειγματοληψίας. Μετά το τελευταίο στρώμα, είτε αυτό είναι στρώμα συνέλιξης είτε υποδειγματοληψίας, ακολουθούν ένα ή περισσότερα πλήρως συνδεδεμένα (fully connected) στρώματα τα οποία παίζουν τον ρόλο του ταξινομητή [4, ενότητα 7.4], [10, 1, 11].




Σχήμα 2.2: Τυπική αρχιτεκτονική ενός CNN [1].

Η αλληλουχία των στρωμάτων συνέλιξης και υποδειγματοληψίας δημιουργούν έναν μετασχηματισμό της εικόνας εισόδου σε έναν **χάρτη χαρακτηριστικών** (feature map). Το τελευταίο στρώμα του CNN είναι ένας ταξινομητής, στον οποίο εισάγεται ως είσοδος αυτός ο χάρτης χαρακτηριστικών. Συνήθως ο ταξινομητής αποτελείται από ένα στρώμα Softmax.

2.3 Η κατηγορία των νευρωνικών δικτύων που λέγονται Autoencoders

Η **αυτοκωδικοποίηση** (autoencoding) είναι η εκπαίδευση ενός νευρωνικού δικτύου να αναπαράγει την είσοδό του στην έξοδο του [12, 13, 14], [4, ενότητα 7.3.3]. Ένας αυτοκωδικοποιητής (autoencoder) είναι ένα νευρωνικό δίκτυο εκπαιδευμένο να μαθαίνει την ταυτοτική συνάρτηση: $\text{output} = \text{input}$.

Μια σχηματική αναπαράσταση αυτού του είδους του νευρωνικού δικτύου φαίνεται στο σχήμα 2.3. Το υπο-δίκτυο που ονομάζεται encoder αντιστοιχεί την είσοδο σε μια **κωδικοποιημένη αναπαράσταση** (embedded representation). Ουσιαστικά είναι η **εσωτερική αναπαράσταση** του autoencoder. Έπειτα το υπο-δίκτυο decoder αντιστοιχεί αυτή την εσωτερική αναπαράσταση



Σχήμα 2.3: Αναπαράσταση ενός autoencoder.

πίσω στην είσοδο.

Πιο αναλυτικά, ο autoencoder συμπιέζει τα δεδομένα εισόδου σε μια εσωτερική αναπαράσταση μικρότερης διάστασης και έπειτα τα ανακατασκευάζει για να πάρει τα δεδομένα εισόδου. Χρησιμοποιείται, μεταξύ άλλων, σε εφαρμογές **απαλοιφής θορύβου**.

Ο encoder είναι υπεύθυνος για την συμπίεση των δεδομένων εισόδου. Η διάσταση στην οποία συμπιέζει τα δεδομένα είναι μικρότερη από αυτήν της εισόδου για να είναι ευκολότερα διαχειρίσιμη. Ωστόσο, κατά τη συμπίεση διατηρείται το μεγαλύτερο ποσοστό της πληροφορίας. Στην έξοδό του ο encoder δίνει ένα συμπιεσμένο διάνυσμα γνωστό και ως **latent representation**. Αυτό το διάνυσμα περιέχει την σημαντικότερη πληροφορία των δεδομένων εισόδου, φιλτράροντας έτσι τον θόρυβο και την περιττή πληροφορία. Κατά την κωδικοποίηση εφαρμόζει μια συνάρτηση στο διάνυσμα εισόδου $x \in \mathbf{R}^n$ και λαμβάνει το συμπιεσμένο διάνυσμα $r \in \mathbf{R}^m$

$$r = f_{compr}(x)$$

Στο τέλος, ο decoder επιφορτίζεται να πάρει την συμπιεσμένη αναπαράσταση και να την αποκωδικοποιήσει πίσω στην πρωτότυπη μορφή, αυτήν που μπήκε ως είσοδος στον autoencoder, δηλαδή εφαρμόζει την συνάρτηση

$$\hat{x} = f_{decompr}(r)$$

Το πόσο καλά θα κάνει την ανακατασκευή βασίζεται στην εκπαίδευση, δηλαδή στην ελαχιστοποίηση του σφάλματος $\text{error} = \text{output} - \text{input}$. Σαφέστατα, επειδή η διάσταση του χώρου συμπίεσης των δεδομένων είναι μικρότερη από την αρχική ($m < n$), το δίκτυο δεν μπορεί να μάθει την ταυτοτική συνάρτηση. Συνεπώς, μοιραία θα υπάρξει απώλεια πληροφορίας, αφού το ανακατασκευασμένο διάνυμα δεν θα είναι ίδιο με το αρχικό:

$$\hat{x} = f_{\text{decompr}}(r) = f_{\text{decompr}}(f_{\text{compr}}(x)) \neq x$$

Στόχος είναι η ελαχιστοποίηση του σφάλματος $e = \hat{x} - x$. Οι συναρτήσεις f_{compr} και f_{decompr} είναι μη γραμμικές.

Σημείωση: Οι autoencoders μαθαίνουν πρότυπα στα δεδομένα χωρίς να χρειάζονται ετικέτες. Είναι δηλαδή μέθοδος μάθησης χωρίς επίβλεψη (μη επιβλεπόμενη μάθηση).

Κεφάλαιο 3


Επικοινωνιακά συστήματα end-to-end με Autoencoders

Όπως αναλύθηκε και στο τέλος του προηγούμενου κεφαλαίου, ο Autoencoder προσπαθεί να ανακτήσει στην έξοδο την είσοδό του [15]. Μπαίνει στην είσοδο ένα σήμα, αλλοιώνεται εξαιτίας του θορύβου του καναλιού και η έξοδος προσπαθεί να το ανακατασκευάσει, δηλαδή να κάνει αποκωδικοποίηση (decode) το ενθόρυβο σήμα. Με αυτή την έννοια ο δέκτης προσπαθεί να αναγνωρίσει το σήμα που δόθηκε στο πομπό, άρα και τον αστερισμό του [16].

Γιατί αυτό είναι χρήσιμο; Διότι ο Autoencoder θα καταφέρει να αναγνωρίσει το σήμα (ενδιαφέρει ο αστερισμός του σήματος) ακόμη και για άγνωστο μοντέλο θορύβου καναλιού. Είναι τέτοια η τεχνολογία/επιστήμη των νευρωνικών ώστε μαθαίνουν από το σφάλμα και προσαρμόζουν τα βάρη τους ώστε να ελαχιστοποιήσουν μια συνάρτηση κόστους. Στη περίπτωση της εργασίας αυτής, το μέγεθος προς ελαχιστοποίηση είναι το Block Error Rate (BLER).

Επειδή στον πραγματικό κόσμο το κανάλι του συστήματος επικοινωνίας δεν είναι ιδανικό, αυτό έχει ως αποτέλεσμα να επιφέρει αλλοιώσεις στο μεταδιδόμενο σήμα. Με άλλα λόγια, το κανάλι είναι η αιτία των σφαλμάτων στην επικοινωνία. Τα σφάλματα μετριοούνται με το μέγεθος BLER.

Η ίδια η δομή του autoencoder επιτρέπει τη μετάφραση ενός τηλεπικοινωνιακού συστήματος, ένα-προς-ένα, ως autoencoder.



Σχήμα 3.1: Αναπαράσταση ενός τηλεπικοινωνιακού συστήματος [2].


Όπως φαίνεται και στο σχήμα 3.1, ολόκληρος ο πομπός θα αναπαρασταθεί ως το υπο-δίκτυο encoder, το κανάλι θα γίνει η εσωτερική αναπαράσταση και ο δέκτης θα γίνει ο decoder. Η κλασική αναπαράσταση του σχήματος 3.1 θεμελιώθηκε από τον Shannon στην ιστορική του δημοσίευση [17].

Με αυτόν τον τρόπο, αναπαρίσταται όλο το σύστημα επικοινωνίας με autoencoder, που είναι και η κύρια μέριμνα της εργασίας. Έτσι αντί να σχεδιάζονται όλα τα blocks του σχήματος 3.1 με μαθηματική ανάλυση και υλοποίηση σε hardware, αυτή η εργασία ανατίθεται σε έναν autoencoder.

Στην εργασία αυτή, κύριο μέλημα του autoencoder είναι να μάθει εσωτερικές αναπαραστάσεις $\mathbf{x}$ μηνυμάτων $\mathbf{s}$ που είναι εύρωστες σε σχέση με τις ατέλειες του καναλιού (θόρυβος, fading, distortion) έτσι ώστε το μεταδιδόμενο μήνυμα να ανακτηθεί με μικρή πιθανότητα σφάλματος. Με άλλα λόγια, κύρια μέριμνα του autoencoder είναι να σχηματίσει κατάλληλα σήματα $\mathbf{x}$ έτσι ώστε να ελαχιστοποιείται το BLER.


3.1 End-to-end αναπαράσταση με autoencoder

Το σύστημα επικοινωνίας του σχήματος 3.2 αναπαρίσταται ως autoencoder.



Σχήμα 3.2: Αναπαράσταση απλής μορφής συστήματος επικοινωνίας.

Το paper [15] προτείνει την υλοποίηση που φαίνεται στο σχήμα 3.3.



Σχήμα 3.3: Σύστημα επικοινωνίας υλοποιημένο ως autoencoder.

Ο πομπός θέλει να επικοινωνήσει ένα από M πιθανά μηνύματα (σύμβολα) $s \in \mathcal{M} = \{1, 2, \dots, M\}$ κάνοντας n διακριτές **χρήσεις καναλιού**. Στο πομπό εφαρμόζει τον μετασχηματισμό $f: \mathcal{M} \rightarrow \mathbf{R}^n$ στο μήνυμα s για να παράξει το μεταδιδόμενο σήμα $x = f(s) \in \mathbf{R}^n$. Το υλικό (hardware) του πομπού επιβάλλει **περιορισμούς** στο σήμα x , παραδείγματος χάρη περιορισμό ενέργειας $\|x\|_n^n \leq n$, περιορισμό πλάτους $|x_i| \leq 1 \forall i$ ή περιορισμό μέσης ισχύος $\mathbf{E}[|x_i|^2] \leq 1 \forall i$.

Ο **ρυθμός επικοινωνίας** είναι $R = k/n$ [bit/channel use], όπου $k = \log_2(M)$. Η σημειογραφία (n, k) σημαίνει ότι το σύστημα επικοινωνίας στέλνει ένα από $M = 2^k$ μηνύματα (k bits έκαστο) μέσω n χρήσεων καναλιού (channel uses). Αν για παράδειγμα το τηλεπικοινωνιακό σύστημα λειτουργεί σε τιμές παραμέτρων $(n, k) = (4, 4)$, τότε τα μηνύματα είναι $M = 2^k = 2^4 = 16$ και αποτελούνται από $k = 4$ bits έκαστο, ενώ καθένα από αυτά τα μηνύματα στέλνονται μέσω τεσσάρων ($n = 4$) χρήσεων καναλιού.

Το κανάλι περιγράφεται από την υπό συνθήκη συνάρτηση πυκνότητας πιθανότητας $p(\mathbf{y}|\mathbf{x})$, όπου $\mathbf{y} \in \mathbf{R}^n$ το λαμβανόμενο σήμα. Λαμβάνοντας το σήμα $\mathbf{y}$, ο δέκτης εφαρμόζει τον μετασχηματισμό $g : \mathbf{R}^n \rightarrow \mathcal{M}$ για να παράξει την εκτίμηση $\hat{s}$ του μεταδιδόμενου μηνύματος s .

Σημείωση: Το σήμα x είναι αυτό που προκύπτει στην έξοδο του πομπού, δηλαδή του encoder. Αυτό πρέπει να είναι εύρωστο, για να επιβιώσει του θορύβου του καναλιού. Οι αστερισμοί που μελετώνται είναι αυτοί του σήματος x .

3.2 Αρχιτεκτονική και εκπαίδευση

3.2.1 Αρχιτεκτονική

Όπως παρατηρείται στο σχήμα 3.3, ο πομπός σχηματίζεται από ένα feedforward neural network με πολλαπλά πυκνά επίπεδα (multiple dense layers) και στο τέλος ένα επίπεδο κανονικοποίησης (normalization layer), το οποίο διασφαλίζει ότι οι φυσικοί περιορισμοί του hardware στο σήμα $\mathbf{x}$ (οι οποίοι προαναφέρθηκαν) τηρούνται. Η είσοδος είναι το μήνυμα s το οποίο μετατρέπεται σε one hot διάνυσμα $\mathbf{1}_s \in \mathbf{R}^M$ με M στήλες, του οποίου το s -στο στοιχείο είναι 1 και τα υπόλοιπα 0.

Το κανάλι περιγράφεται από ένα επίπεδο προσθετικού θορύβου με σταθερή διαχύμανση $\beta = (2RE_b/N_0)^{-1}$ όπου το E_b/N_0 συμβολίζει την ενέργεια κάθε bit, E_b , προς την φασματική πυκνότητα ισχύος θορύβου, N_0 . Με άλλα λόγια η ποσότητα E_b/N_0 είναι ο λόγος σήματος προς θόρυβο (Signal-to-Noise ratio - SNR).

Ο δέκτης περιγράφεται επίσης από ένα feedforward neural network. Το τελευταίο επίπεδο χρησιμοποιεί softmax συνάρτηση ενεργοποίησης, της οποίας η έξοδος $\mathbf{p} \in (0, 1)^M$ είναι ένα διάνυσμα πιθανοτήτων όλων των πιθανών μηνυμάτων, με την πιθανότητα να είναι στο εύρος 0 έως 1. Το στοιχείο του διανύσματος $\mathbf{p}$ με την μεγαλύτερη πιθανότητα αντιστοιχεί στο αποκωδικοποιημένο μήνυμα $\hat{s}$.

3.2.2 Εκπαίδευση

Ο autoencoder εκπαιδεύεται από άκρο σε άκρο με τον αλγόριθμο SGD (βλ. ενότητα 2.1.2) σε όλα τα πιθανά μηνύματα $s \in \mathcal{M}$ χρησιμοποιώντας ως συνάρτηση κόστους (σφάλματος) την συνάρτηση categorical cross entropy μεταξύ των διανυσμάτων $\mathbf{1}_s$ και $\mathbf{p}$. Το σφάλμα είναι $e = \hat{s} - s$ ή σε διανυσματική μορφή $\mathbf{e} = \mathbf{p} - \mathbf{1}_s$.

Σημείωση: η συνάρτηση categorical cross entropy ορίζεται ως εξής

$$-\sum_j u_j \log(v_j)$$

όπου $\mathbf{u}$ η είσοδος και $\mathbf{v}$ η έξοδος. Εδώ, $\mathbf{u} = \mathbf{1}_s$ και $\mathbf{v} = \mathbf{p}$ αντίστοιχα.

Σε αυτό το σημείο είναι αναγκαίος ο ορισμός του BLER ως ο **αριθμός λανθασμένων μηνυμάτων προς τον αριθμό απεσταλμένων μηνυμάτων**. Το κάθε μήνυμα αποτελείται από bits. Αν γίνει λάθος έστω και σε ένα bit τότε θεωρείται λανθασμένο ολόκληρο το μήνυμα. Αν στάλθηκαν 10 μηνύματα και τα λανθασμένα ήταν 5, τότε το BLER είναι $5/10 = 0.5$.

Ως μέγεθος το BLER είναι αυστηρότερο του Bit Error Rate, το οποίο βλέπει λάθη σε μεμονωμένα bits.

Δεδομένα Εκπαίδευσης

Ως δεδομένα εκπαίδευσης χρησιμοποιούνται 10.000 ακέραιοι αριθμοί στο εύρος 0 έως $M - 1$, σε τυχαία σειρά. Αυτοί οι αριθμοί αντιπροσωπεύουν τα M μηνύματα. Σε αυτό το σύνολο εκπαιδεύεται ο autoencoder. Φυσικά, για να καταλάβει το νευρωνικό αυτούς τους αριθμούς, μετατρέπονται σε one-hot διανύσματα.

Δεδομένα Ελέγχου

Για τα δεδομένα ελέγχου δημιουργείται ένα dataset 500.000 τυχαίων αριθμών σε όλο το εύρος 0 έως $M - 1$, με ίδια πιθανότητα εμφάνισης κάθε μηνύματος. Τα 500.000 δείγματα αναμένεται να προσδώσουν **στατιστική επάρκεια** στον έλεγχο του νευρωνικού δικτύου.

Καθόλη τη διάρκεια της εκπαίδευσης ο αστερισμός εξελίσσεται. Σε κάθε εποχή ο autoencoder τοποθετεί τα σύμβολα στο I/Q επίπεδο. Σε κάθε εποχή ο autoencoder στέλνει μηνύματα και τα ανακτεί. Αν υπάρχει σφάλμα διορθώνει τα βάρη μέσω του αλγορίθμου back-propagation. Έτσι σε κάθε εποχή ο αστερισμός αλλάζει μορφή. Τα σύμβολα συνεχώς μετακινούνται μέχρι να πάρουν την τελική τους βέλτιστη θέση στο τέλος της εκπαίδευσης.

Αν τα σύμβολα είναι πολύ κοντά, ο θόρυβος AWGN θα τα μπερδέψει. Στο τέλος θα είναι τόσο μακριά το ένα από το άλλο όσο χρειάζεται για την ελαχιστοποίηση του BLER. Αυτός είναι και ο βέλτιστος αστερισμός που έμαθε ο autoencoder, μόνος του, χωρίς τη βοήθεια ανθρώπου, απλώς ανανεώνοντας σε κάθε εποχή τα βάρη των νευρωνικών δικτύων που τον απαρτίζουν.

Ο autoencoder εκπαιδεύεται σε σταθερό θόρυβο $E_b/N_0 = 7$ dB. Όμως η επίδοσή του στα 500.000 μηνύματα του test set ελέγχεται στο εύρος -4 έως 12 dB.

3.3 Εκμάθηση αστερισμών σε κανάλι AWGN

Έστω ότι τα μηνύματα είναι $M = 16$. Αυτά αριθμούνται ως ακέραιοι αριθμοί, δηλαδή μήνυμα 0, μήνυμα 1, ..., μήνυμα 15. Το κάθε μήνυμα είναι αυθαίρετο, μπορεί να σημαίνει οτιδήποτε, π.χ. ‘καλημέρα’. Καθένα από αυτά τα 16 μηνύματα μετατρέπονται σε one-hot διανύσματα. Παιρνάνε από τον encoder και δημιουργείται το μεταδιδόμενο σήμα x . Αυτό είναι το σήμα που θα μεταδοθεί στο κανάλι. Ο autoencoder το φτιάχνει εύρωστο (κατά τη διάρκεια της εκπαίδευσης), δηλαδή διαμορφώνει τον αστερισμό με τέτοιο τρόπο ώστε οι περιοχές απόφασης να είναι ευρείες, βοηθώντας την επιτυχία (με το μικρότερο δυνατό σφάλμα) ανάκτησή του από τον δέκτη.

Πρέπει να τονιστεί ότι το σήμα x το κατασκευάζει αποκλειστικά ο autoencoder, με τρόπο βέλτιστο για την μετάδοσή του στο κανάλι. Ως εκ τούτου, ο αστερισμός του σήματος x είναι ο αστερισμός που δημιούργησε μόνος του ο autoencoder.

Το σήμα x είναι η έξοδος του encoder. Για $n = 2$, ο encoder παίρνει το one-hot διάνυσμα και το συμπυκνώνει σε δύο αριθμούς. Αυτές είναι οι συντεταγμένες του συμβόλου στο I/Q επίπεδο. Το σύμβολο δηλαδή είναι ένα διάνυσμα $n = 2$ αριθμών.

Ο autoencoder ερμηνεύει την επικοινωνία ως **πρόβλημα ανακατασκευής**. Δηλαδή στην έξοδο θα προσπαθήσει να δώσει το μήνυμα που μπήκε στην είσοδο. Έτσι, εφευρίσκει δικούς του αστερισμούς, τοποθετώντας τα σύμβολα κατάλληλα στο επίπεδο δημιουργώντας περιοχές απόφασης τέτοιες που ακόμη κι αν ο θόρυβος του καναλιού μετακινήσει τα σύμβολα, ο δέκτης να είναι σε θέση να αναγνωρίσει το αρχικό σύμβολο, δηλαδή το σύμβολο του σήματος x .

Στην είσοδο μπαίνουν one-hot διανύσματα. Στην έξοδο προκύπτει διάνυσμα πιθανοτήτων. Μια επιτυχής αναγνώριση του μηνύματος 0 θα έμοιαζε έτσι:

μήνυμα 0 = [1, 0, ..., 0]


έξοδος = [0.98, 0, ..., 0]

Ο autoencoder εκπαιδεύεται σε 10.000 τυχαία μηνύματα, στο εύρος 0 έως $M - 1$. Ο κώδικας Python τυπώνει τον αστερισμό κάθε 10 εποχές πριν αυτός μπει στο κανάλι.

Πείραμα 1: κανέναν περιορισμό ισχύος

Στο πρώτο πείραμα δεν επιβάλλεται κανέναν περιορισμός ισχύος στα σύμβολα. Ο autoencoder αφήνεται ελεύθερος να τα τοποθετήσει όπου κρίνει αυτός στο IQ επίπεδο.


Εξέλιξη Αστερισμού: Σύστημα (2,2) - Χωρίς Περιορισμό



Σχήμα 3.4: Εξέλιξη αστερισμού για σύστημα (2,2) χωρίς περιορισμό ισχύος.

Πίνακας 3.1: Αποτελέσματα προσομοίωσης Monte Carlo ($N_{test} = 500.000$) για το σύστημα (2,2) χωρίς περιορισμό ισχύος.

E_b/N_0 (dB)	Λάθη / Δείγματα	BLER
-4.0	10.184 / 500.000	0,02037
-3.0	5.626 / 500.000	0,01125
-2.0	2.863 / 500.000	0,00573
-1.0	1.253 / 500.000	0,00251
0.0	461 / 500.000	0,00092
1.0	116 / 500.000	0,00023
2.0	38 / 500.000	0,00008
3.0	3 / 500.000	0,00001
4.0	1 / 500.000	0,00000
5.0	0 / 500.000	0,00000
6.0	0 / 500.000	0,00000
7.0	0 / 500.000	0,00000
8.0	0 / 500.000	0,00000
9.0	0 / 500.000	0,00000
10.0	0 / 500.000	0,00000
11.0	0 / 500.000	0,00000
12.0	0 / 500.000	0,00000



Σχήμα 3.5: BLER για σύστημα (2,2) χωρίς περιορισμό ισχύος.


Στο σχήμα 3.4 φαίνεται η εξέλιξη του αστερισμού κάθε 10 εποχές. Ξεκινώντας από μια αρχική θέση, ο autoencoder μετακινεί τα σύμβολα έτσι ώστε να μειώσει το BLER, το οποίο φαίνεται στο σχήμα 3.5.

Μια πολύ σημαντική παρατήρηση είναι ότι, απουσία περιορισμού ισχύος, ο autoencoder τοποθετεί τα σύμβολα όσο μακριά από την αρχή των αξόνων κρίνει απαραίτητο. Αυτό φυσικά στον πραγματικό κόσμο δεν υφίσταται, αφού οι περιορισμοί ισχύος που επιβάλλει το hardware αναγκάζουν τα σύμβολα να είναι κοντά στην αρχή των αξόνων.

Το σχήμα 3.5 είναι αποκαλυπτικό. Προκύπτει από τις μετρήσεις του πίνακα 3.1. Για λόγο σήματος προς θόρυβο $SNR = -4$ dB, το BLER είναι της τάξεως του 10^{-1} , δηλαδή το 10% των μηνυμάτων φτάνει στον δέκτη με σφάλμα. Καθώς αυξάνει το SNR, το BLER μειώνει, αφού το σήμα γίνεται

ισχυρότερο και μπορεί να αντιμετωπίσει τον θόρυβο. Στα 7 dB και έπειτα, το BLER έχει πάει στο 10^{-5} , πρακτικά μηδαμινό.


Εξέλιξη Αστερισμού: Σύστημα (2,4) - Χωρίς Περιορισμό



Σχήμα 3.6: Εξέλιξη αστερισμού για σύστημα (2,4) χωρίς περιορισμό ισχύος.

Πίνακας 3.2: Αποτελέσματα προσομοίωσης Monte Carlo ($N_{test} = 500.000$) για το σύστημα (2,4) χωρίς περιορισμό ισχύος.

E_b/N_0 (dB)	Λάθη / Δείγματα	BLER
-4.0	3.688 / 500.000	0,00738
-3.0	1.492 / 500.000	0,00298
-2.0	479 / 500.000	0,00096
-1.0	139 / 500.000	0,00028
0.0	28 / 500.000	0,00006
1.0	7 / 500.000	0,00001
2.0	1 / 500.000	0,00000
3.0	0 / 500.000	0,00000
4.0	0 / 500.000	0,00000
5.0	0 / 500.000	0,00000
6.0	0 / 500.000	0,00000
7.0	0 / 500.000	0,00000
8.0	0 / 500.000	0,00000
9.0	0 / 500.000	0,00000
10.0	0 / 500.000	0,00000
11.0	0 / 500.000	0,00000
12.0	0 / 500.000	0,00000



Σχήμα 3.7: BLER για σύστημα (2,4) χωρίς περιορισμό ισχύος.

Στο σχήμα 3.6 παρουσιάζεται ο αστερισμός 16 συμβόλων. Στις 0 εποχές τα σύμβολα είναι τυχαία κατανεμημένα. Με την παρόδο των εποχών, ο autoencoder τα απωθεί από την αρχή των αξόνων, απλώνοντας τα στο επίπεδο. Αν ληφθεί υπόψη η κλίμακα των αξόνων x και y θα γίνει αντιληπτό ότι τα σύμβολα είναι πολύ μακριά από την αρχή των αξόνων, άρα έχουν και μεγάλη ενέργεια. Αυτό είναι απαγορευτικό για την κατανάλωση ενέργειας του hardware του πομπού και του δέκτη, για αυτό επιβάλλουν περιορισμούς ισχύος όπως θα γίνει στην επόμενη ενότητα.

Στο σχήμα 3.7, που προκύπτει από τον πίνακα 3.2, παρατηρείται ότι ήδη στα 0 dB το BLER πέφτει κάτω από το 10^{-4} .


3.4 Επίδραση των περιορισμών ισχύος

Ο autoencoder είναι σε θέση να **επινοήσει αστερισμούς**. Το αξιοθαύμαστο είναι ότι έχει την ικανότητα να επινοήσει ήδη υπάρχοντες αστερισμούς. Ένα τέτοιο παράδειγμα αποτελεί ο αστερισμός με περιορισμό μέσης ισχύος.

Πομπός και δέκτης βελτιστοποιούνται ταυτόχρονα για να ελαχιστοποιήσουν το BLER. Για να γίνει αυτό, ο autoencoder μαθαίνει να τοποθετεί τα σύμβολα όσο το δυνατόν πιο μακριά το ένα από το άλλο.

Πείραμα 2: περιορισμός μέσης ισχύος


Επιβάλλεται περιορισμός μέσης ισχύος (average power constraint) σε ολόκληρο τον αστερισμό. Αυτό σημαίνει ότι κάποια σύμβολα θα έχουν περισσότερη ισχύ από άλλα, κάποια λιγότερη από άλλα, αλλά κατά μέσο όρο η ισχύς θα είναι σταθερή.



Σχήμα 3.8: Εξέλιξη αστερισμού για σύστημα (2,2) με περιορισμό μέσης ισχύος.


Πίνακας 3.3: Αποτελέσματα προσομοίωσης Monte Carlo ($N_{test} = 500.000$) για το σύστημα (2,2) με περιορισμό μέσης ισχύος.

E_b/N_0 (dB)	Λάθη / Δείγματα	BLER
-4.0	169.842 / 500.000	0,33968
-3.0	147.112 / 500.000	0,29422
-2.0	123.839 / 500.000	0,24768
-1.0	99.897 / 500.000	0,19979
0.0	76.980 / 500.000	0,15396
1.0	56.221 / 500.000	0,11244
2.0	38.071 / 500.000	0,07614
3.0	23.528 / 500.000	0,04706
4.0	13.020 / 500.000	0,02604
5.0	6.371 / 500.000	0,01274
6.0	2.641 / 500.000	0,00528
7.0	920 / 500.000	0,00184
8.0	231 / 500.000	0,00046
9.0	38 / 500.000	0,00008
10.0	8 / 500.000	0,00002
11.0	0 / 500.000	0,00000
12.0	0 / 500.000	0,00000



Σχήμα 3.9: BLER για σύστημα (2,2) με περιορισμό μέσης ισχύος.


Το σχήμα 3.9 προκύπτει από τις μετρήσεις του πίνακα 3.3.



Σχήμα 3.10: Εξέλιξη αστερισμού για σύστημα (2,4) με περιορισμό μέσης ισχύος.

Πίνακας 3.4: Αποτελέσματα προσομοίωσης Monte Carlo ($N_{test} = 500.000$) για το σύστημα (2,4) με περιορισμό μέσης ισχύος.

E_b/N_0 (dB)	Λάθη / Δείγματα	BLER
-4.0	337.427 / 500.000	0,67485
-3.0	316.692 / 500.000	0,63338
-2.0	293.871 / 500.000	0,58774
-1.0	267.992 / 500.000	0,53598
0.0	239.435 / 500.000	0,47887
1.0	208.205 / 500.000	0,41641
2.0	176.187 / 500.000	0,35237
3.0	142.841 / 500.000	0,28568
4.0	110.992 / 500.000	0,22198
5.0	81.349 / 500.000	0,16270
6.0	55.828 / 500.000	0,11166
7.0	35.327 / 500.000	0,07065
8.0	20.142 / 500.000	0,04028
9.0	10.569 / 500.000	0,02114
10.0	4.661 / 500.000	0,00932
11.0	1.837 / 500.000	0,00367
12.0	576 / 500.000	0,00115



Σχήμα 3.11: BLER για σύστημα (2,4) με περιορισμό μέσης ισχύος.

Το σχήμα 3.11 προκύπτει από τις μετρήσεις του πίνακα 3.4.


Στα σχήματα 3.8, 3.10 φαίνεται η εξέλιξη των αστερισμών συναρτήσει των εποχών. Από μια αρχική θέση, τα σύμβολα απομακρύνονται μεταξύ τους με την πάροδο των εποχών, καταλήγοντας σε θέσεις πιο κοντά και πιο μακριά από την αρχή των αξόνων, έτσι ώστε η συνολική μέση ισχύς να παραμένει σταθερή.

Ο αστερισμός του σχήματος 3.8 μοιάζει με τον αστερισμό Q-PSK, ελαφρώς περιστραμμένος. Ο αστερισμός του σχήματος 3.10 μοιάζει με τον αστερισμό 16-APSK, αφού δεν τοποθετεί τα σύμβολα σε ένα τετράγωνο πλέγμα αλλά σε **ομόκεντρους δακτυλίους**. Το μεγαλύτερο θαύμα της βαθιάς μάθησης αποτελεί ότι έμαθε εντελώς μόνη της πως να κατασκευάζει αυτόν τον αστερισμό!

Πείραμα 3: περιορισμός μέσης ισχύος ανά σύμβολο

Στο τρίτο και τελευταίο πείραμα, επιβάλλεται περιορισμός μέσης ισχύος σε κάθε σύμβολο. Αυτό σημαίνει ότι όλα τα σύμβολα θα ισαπέχουν από την αρχή των αξόνων, ενώ ταυτόχρονα θα προσπαθούν να απέχουν μεταξύ τους το δυνατόν μεγαλύτερη απόσταση.


Εξέλιξη Αστερισμού: Σύστημα (2, 2)
(Αυστηρός Περιορισμός - Όλα τα σύμβολα πάνω στον κύκλο)



Σχήμα 3.12: Εξέλιξη αστερισμού για σύστημα (2,2) με περιορισμό μέσης ισχύος ανά σύμβολο.

Πίνακας 3.5: Αποτελέσματα προσομοίωσης Monte Carlo ($N_{test} = 500.000$) για το σύστημα (2,2) με περιορισμό ισχύος ανά σύμβολο.


E_b/N_0 (dB)	Λάθη / Δείγματα	BLER
-4.0	170.200 / 500.000	0,34040
-3.0	146.787 / 500.000	0,29357
-2.0	123.326 / 500.000	0,24665
-1.0	99.202 / 500.000	0,19840
0.0	76.867 / 500.000	0,15373
1.0	55.889 / 500.000	0,11178
2.0	37.522 / 500.000	0,07504
3.0	23.369 / 500.000	0,04674
4.0	13.024 / 500.000	0,02605
5.0	6.417 / 500.000	0,01283
6.0	2.578 / 500.000	0,00516
7.0	867 / 500.000	0,00173
8.0	245 / 500.000	0,00049
9.0	41 / 500.000	0,00008
10.0	5 / 500.000	0,00001
11.0	0 / 500.000	0,00000
12.0	0 / 500.000	0,00000



Σχήμα 3.13: BLER για σύστημα (2,2) με περιορισμό μέσης ισχύος ανά σύμβολο.

Το σχήμα 3.13 προκύπτει από τις μετρήσεις του πίνακα 3.5.


Εξέλιξη Αστερισμού: Σύστημα (2, 4)
(Αυστηρός Περιορισμός - Όλα τα σύμβολα πάνω στον κύκλο)



Σχήμα 3.14: Εξέλιξη αστερισμού για σύστημα (2,4) με περιορισμό μέσης ισχύος ανά σύμβολο.

Πίνακας 3.6: Αποτελέσματα προσομοίωσης Monte Carlo ($N_{test} = 500.000$) για το σύστημα (2,4) με περιορισμό ισχύος ανά σύμβολο.

E_b/N_0 (dB)	Λάθη / Δείγματα	BLER
-4.0	362.706 / 500.000	0,72541
-3.0	347.916 / 500.000	0,69583
-2.0	330.382 / 500.000	0,66076
-1.0	311.271 / 500.000	0,62254
0.0	290.646 / 500.000	0,58129
1.0	268.965 / 500.000	0,53793
2.0	244.486 / 500.000	0,48897
3.0	219.109 / 500.000	0,43822
4.0	192.183 / 500.000	0,38437
5.0	165.018 / 500.000	0,33004
6.0	137.314 / 500.000	0,27463
7.0	111.008 / 500.000	0,22202
8.0	85.991 / 500.000	0,17198
9.0	62.714 / 500.000	0,12543
10.0	43.742 / 500.000	0,08748
11.0	28.130 / 500.000	0,05626
12.0	16.536 / 500.000	0,03307



Σχήμα 3.15: BLER για σύστημα (2,4) με περιορισμό μέσης ισχύος ανά σύμβολο.

Το σχήμα 3.15 προκύπτει από τις μετρήσεις του πίνακα 3.6.

Παρατηρώντας τα σχήματα 3.12 και 3.14 φαίνεται ότι όλα τα σύμβολα βρίσκονται επάνω στον ίδιο κύκλο, οπότε ο αστερισμός μοιάζει με τον 4-PSK και 16-PSK αντίστοιχα. Συνάμα, από τα σχήματα 3.9, 3.11 και 3.13, 3.15 συνάγεται το συμπέρασμα ότι ο περιορισμός μέσης ισχύος ανά σύμβολο (πείραμα 3) αντί για συνολικά στον αστερισμό (πείραμα 2) συνεπάγεται αύξηση του BLER.


Αυτό εξηγείται με βάση τη **γεωμετρία του αστερισμού**. Στο σχήμα 3.14, οι περιοχές απόφασης είναι 16 φέτες, σαν 16 κομμάτια πίτσας. Αυτά τα κομμάτια είναι πολύ στενά, απέχοντας μόλις $360/16 = 22.5$ μοίρες μεταξύ τους, οπότε εύκολα ο θόρυβος μετακινεί ένα σύμβολο σε περιοχή απόφασης διπλανού συμβόλου. Αντίθετα, στον αστερισμό του σχήματος 3.10 (που όπως ειπώθηκε μοιάζει με 16-APSK), οι περιοχές απόφασης που δημιουργούνται είναι κυψελοειδής. Ο χώρος που

έχει το κάθε σύμβολο είναι μεγαλύτερος, γι' αυτό και η απόδοσή του σε BLER είναι καλύτερη.

3.5 Σύγκριση απόδοσης: Autoencoder vs κλασικές μέθοδοι


Σε αυτή την ενότητα παρατίθενται γραφήματα που δείχνουν τη σύγκριση μεταξύ των συστημάτων (2,2) και (2,4) όταν υλοποιούνται ως autoencoders, καθώς και τη σύγκριση του autoencoder(7,4) με τον κώδικα Hamming(7,4).

3.5.1 Σύγκριση μεταξύ Autoencoders



Σχήμα 3.16: Σύγκριση BLER για Autoencoder(2,2) σε όλους τους περιορισμούς ισχύος.

Στο σχήμα 3.16 φαίνεται το BLER συναρτήσει του $\text{SNR} = E_b/N_0$ για τα τρία πειράματα των προηγούμενων ενοτήτων. Παρατηρείται ότι απουσία περιορισμού, το BLER μηδενίζεται ήδη από τα 3 dB ενώ η απόδοση (σε όρους BLER) του autoencoder για τους περιορισμούς μέσης ενέργειας και μέσης ενέργειας ανά σύμβολο είναι εφάμιλλη. Αυτό συμβαίνει διότι οι αστερισμοί για το σύστημα (2,2), για τους δύο αυτούς περιορισμούς, είναι πρακτικά ισοδύναμοι (4-PSK), αφού όλα τα σύμβολα ισαπέχουν από την αρχή των αξόνων.



Σχήμα 3.17: Σύγκριση BLER για Autoencoder(2,4) σε όλους τους περιορισμούς ισχύος.

Από τη μελέτη του σχήματος 3.17 διαφαίνεται η ξεκάθαρη νίκη του περιορισμού μέσης ισχύος έναντι του περιορισμού ισχύος ανά σύμβολο. Αυτό συμβαίνει διότι ο περιορισμός μέσης ισχύος στο σύνολο του αστερισμού δίνει μεγαλύτερη ελευθερία και ευελιξία στον autoencoder να τοποθετήσει τα σύμβολα στο επίπεδο. Φαίνεται και από τα σχήματα 3.10, 3.14 ότι ο περιορισμός ισχύος ανά σύμβολο περιορίζει την τοποθέτηση των συμβόλων πάνω στον κύκλο (διαμόρφωση τύπου PSK), ενώ ο περιορισμός μέσης ισχύος απλώνει τα σύμβολα στο χώρο σε διατάξεις που μοιάζουν στη


διαμόρφωση APSK, η οποία είναι σαφώς ανώτερη και αποτελεσματικότερη της PSK.

3.5.2 Σύγκριση μεταξύ Autoencoder και Hamming

Εφόσον ο περιορισμός μέσης ισχύος συνολικά στον αστερισμό έχει μικρότερο BLER θα χρησιμοποιηθεί ως βάση για τις συγκρίσεις που θα ακολουθήσουν. Συγκεκριμένα θα συγκριθούν ο autoencoder (2,4) με την παραδοσιακή διαμόρφωση 16-QAM και ο autoencoder (7,4) με τον κώδικα Hamming (7,4) [18, κεφάλαιο 8].

Ο κώδικας Hamming(7,4) είναι ένας **κώδικας διόρθωσης σφαλμάτων** [19, κεφάλαιο 3]. Εντοπίζει και διορθώνει το bit που μεταδόθηκε εσφαλμένα λόγω θορύβου. Για κάθε $k = 4$ bits πληροφορίας, ο πομπός στέλνει $n = 7$ bits. Τα $n - k = 3$ bits ονομάζονται **bit ισοτιμίας** (parity bits), τα οποία προστατεύουν το μήνυμα από σφάλματα. Τα $n = 7$ bits που στέλνει ο πομπός πακετίζονται σε ένα διάνυσμα $n = 7$ διαστάσεων. Το σύμβολο λοιπόν που στέλνει ο πομπός αποτυπώνεται στον **7-διάστατο χώρο**. Ως εκ τούτου, υπάρχει πολύ περισσότερος χώρος να τοποθετηθούν τα σύμβολα από ότι στο 2-διάστατο χώρο.


Η **αποκωδικοποίηση μέγιστης πιθανοφάνειας** (Maximum Likelihood Decoding - MLD) είναι ο μαθηματικά βέλτιστος τρόπος να μαντέψει ο δέκτης ποιο μήνυμα (σύμβολο) έστειλε ο πομπός. Χρησιμοποιεί Soft Decision. Τα **Soft Decision** και **Hard Decision** γίνονται περισσότερο κατανοητά με ένα παράδειγμα. Το κανάλι προσθέτει θόρυβο, οπότε ένα bit που στάλθηκε ως 0 μπορεί να φτάσει στο δέκτη ως 0.6 και ένα bit που στάλθηκε ως 1 μπορεί να φτάσει ως 0.4. Το Hard Decision λειτουργεί ως σκληρός κριτής: οτιδήποτε κάτω από 0.5 γίνεται 0 και οτιδήποτε πάνω από 0.5 γίνεται 1. Άρα τα 0.6 και 0.8 γίνονται 1 και 0 αντίστοιχα, όμως στάλθηκαν ως 0 και 1, άρα ο δέκτης τα αναγνώρισε λανθασμένα! Το Soft Decision διατηρεί τα 0.4 και 0.8.



Σχήμα 3.18: Σύγκριση BLER: Autoencoder(2,4) vs 16-QAM.

Στο σχήμα 3.18 παρατηρείται ότι ο autoencoder(2,4) παρουσιάζει εξαιρετικά παρόμοιο BLER με την κλασική διαμόρφωση 16-QAM. Αυτό καταδεικνύει ότι η βαθιά μάθηση (ο autoencoder) κατάφερε μόνη της, χωρίς γνώσεις μαθηματικών και τηλεπικοινωνιών, να φτιάξει μια διαμόρφωση με σχεδόν ίδια απόδοση σε BLER. Βέβαια, από τα 12 dB και έπειτα, ο autoencoder υστερεί αισθητά.

Αυτό συμβαίνει διότι ο αστερισμός που μαθαίνει ο autoencoder(2,4) μοιάζει με τον 16-APSK (σχήμα 3.10), ο οποίος υστερεί ελαφρώς του 16-QAM (σε περιβάλλον AWGN) όσον αφορά την ευκλείδια απόσταση μεταξύ των σημείων. Σε περιβάλλον AWGN, η διαμόρφωση 16-QAM προσφέρει μεγαλύτερη ευκλείδια απόσταση μεταξύ των συμβόλων, κερδίζοντας σε BLER.



Σχήμα 3.19: Σύγκριση BLER: Autoencoder(7,4) vs Hamming(7,4).


Ενώ ο autoencoder (2,4) συναγωνίστηκε την διαμόρφωση 16-QAM δεν συμβαίνει το ίδιο με τον autoencoder (7,4) και τον αλγόριθμο Hamming (7,4) - MLD. Στο σχήμα 3.19 φαίνεται ξεκάθαρα το προβάδισμα του παραδοσιακού αλγορίθμου έναντι της βαθιάς μάθησης. Στα 8 dB ο autoencoder παρουσιάζει BLER 10^{-4} ενώ ο Hamming 10^{-5} , μια ολόκληρη τάξη μεγέθους. Φυσικά η ψαλίδα στην απόδοση ανοίγει ήδη από τα 3 dB και συνεχίζει να αυξάνει καθώς αυξάνει το SNR.

Η ήττα του autoencoder(7,4) από τον κώδικα Hamming(7,4) - Soft Decision οφείλεται στην μαθηματική υπεροχή του δεύτερου. Είναι ο μαθηματικά ιδανικός τρόπος να τοποθετηθούν 16 σύμβολα στον 7-διάστατο χώρο ώστε να απέχουν το ένα από το άλλο τη μέγιστη δυνατή απόσταση. Ο Autoencoder(7,4) προσπαθεί να κάνει το ίδιο, αλλά χωρίς να γνωρίζει μαθηματικά, παρά μόνο μεταβάλλοντας τα βάρη (με backpropagation). Ως εκ τούτου, μπορεί να πλησιάσει αλλά όχι να ξεπεράσει την μαθηματική τελειότητα του κώδικα Hamming(7,4) - Soft Decision.

Τώρα η σύγκριση γίνεται ανάμεσα στον Autoencoder (7,4) και στον κώδικα Hamming(7,4) Hard Decision και παρατηρείται η επικράτηση του πρώτου. Αυτό συμβαίνει διότι ο αλγόριθμος Hamming(7,4) - Hard Decision είναι πιο 'σκληρός' στην αποκωδικοποίηση των συμβόλων, όπως εξηγήθηκε σε παραπάνω παράγραφο.

3.5.3 Περισσότερα κρυφά επίπεδα στο νευρωνικό του Autoencoder

Πραγματοποιούνται πειράματα με μεγέθυνση της αρχιτεκτονικής του νευρωνικού δικτύου. Συγκεκριμένα, προστίθεται ακόμη ένα κρυφό επίπεδο με ReLU συνάρτηση ενεργοποίησης στον πομπό, το ίδιο και στον δέκτη. Εκτελείται το ίδιο πείραμα με πριν για να διαπιστωθεί εάν η αύξηση του βάθους του νευρωνικού βελτιώνει την απόδοσή του.




Σχήμα 3.20: Σύγκριση BLER: Autoencoder(7,4) vs Hamming(7,4).

Τα αποτελέσματα παρουσιάζονται στο σχήμα 3.20. Ακόμη και με περισσότερα κρυφά επίπεδα, ο autoencoder(7,4) δεν κατάφερε να νικήσει τον κώδικα Hamming(7,4) - MLD. Αυτό καταδεικνύει έμπρακτα ότι η βαθιά μάθηση δεν μπορεί να υπερνικήσει τον κλασικό αλγόριθμο Hamming - MLD.

3.5.4 Το πρόβλημα της τυχαίας στροφής φάσης

Το τελικό μας πείραμα είναι το εξής: το κανάλι εισάγει μια **τυχαία στροφή** στην φάση του σήματος στο εύρος $[0, 45]$ μοίρες και $[0, 90]$ μοίρες. Το κάθε μήνυμα που στέλνει ο πομπός αποτελεί και ένα σύμβολο. Αυτό το σύμβολο γίνεται το σήμα x με περνάει μέσα από το κανάλι. Το κανάλι προσθέτει θόρυβο και στρέφει τη φάση κατά μια τυχαία γωνία, μέσα στο εύρος $[0,45]$ και $[0,90]$ μοίρες αντίστοιχα. **Κάθε σύμβολο θα υποστεί διαφορετική στροφή φάσης.**



Σχήμα 3.21: Σύγκριση BLER: Autoencoder(7,4) vs Hamming(7,4) σε στροφή φάσης $[0,45]$ μοίρες (αριστερά) και σε $[0,90]$ μοίρες (δεξιά).

Το σχήμα 3.21 δείχνει γλαφυρά την νίκη του autoencoder (δηλαδή της βαθιάς μάθησης) έναντι της κλασικής τηλεπικοινωνιακής θεωρίας. Ο autoencoder κατάφερε να μάθει να αντιμετωπίζει την τυχαία στροφή φάσης χωρίς πρότερη γνώση και προσαρμόστηκε ([15]). Ο κώδικας Hamming απέτυχε παταγωδώς. Σημαντική παρατήρηση αποτελεί ότι στο αριστερό σχήμα, στα 8 dB το BLER είναι 10^{-4} ενώ στο δεξί 10^{-3} , αφού το εύρος $[0,90]$ είναι μεγαλύτερο, οπότε και ο autoencoder

δυσκολεύτηκε να μειώσει τόσο πολύ το σφάλμα. Λογικό, αφού το εύρος $[0,90]$ μοίρες είναι πολύ μεγάλο για να μάθει η βαθιά μάθηση να το αντιμετωπίζει.

Η νίκη του autoencoder βασίζεται στην παρατήρηση του εκπεμπόμενου συμβόλου και του λαμβανόμενου συμβόλου, και κατόπιν στην προσαρμογή των βαρών έτσι ώστε να ελαχιστοποιήσει το σφάλμα. Έτσι, **επινοεί γεωμετρικές αστερισμών** οι οποίες καταφέρνουν να αναγνωρίσουν το σύμβολο που στάλθηκε, ακόμη κι αν το κάθε σύμβολο υποβλήθηκε σε μια τυχαία περιστροφή.

Ο αλγόριθμος Hamming ακόμη κι αν θριαμβεύει στην αφαίρεση AWGN θορύβου, είναι αδύναμος στο σχηματισμό δυναμικών περιοχών απόφασης. Στο πρόβλημα της τυχαίας στροφής φάσης, βλέπει ένα σύμβολο να πέρασε (λόγω στροφής φάσης) στη περιοχή απόφασης ενός άλλου συμβόλου, οπότε το αναγνωρίζει ως σφάλμα. Αντίθετα, ο autoencoder σχηματίζει νέες περιοχές απόφασης, και αναγνωρίζει επιτυχώς τα μετακινημένα σύμβολα.

Κεφάλαιο 4

Συστήματα Πολλών Εισόδων - Πολλών Εξόδων

Στο παρόν κεφάλαιο θα συζητηθούν τα τηλεπικοινωνιακά συστήματα πολλών εισόδων και εξόδων, δηλαδή τα Multiple Inputs - Multiple Outputs (MIMO) τηλεπικοινωνιακά συστήματα [20]. Ένα τηλεπικοινωνιακό σύστημα πολλές φορές έχει πάνω από ένα ζευγάρι πομπών και δεκτών, τα οποία μοιράζονται το **ίδιο** κανάλι και **ανταγωνίζονται** για τη χρήση του. Θα μελετηθεί αν και πώς η βαθιά μάθηση μπορεί να αντιμετωπίσει προβλήματα παρεμβολών και αν τα καταφέρνει καλύτερα από τις παραδοσιακές μεθόδους.

4.1 Δύο χρήστες σε AWGN κανάλι με παρεμβολές

Το σύστημα δύο χρηστών με κοινό AWGN κανάλι αντιμετωπίζεται όπως φαίνεται στο σχήμα 4.1. Στο σύστημα αυτό, ο πομπός 1 θέλει να επικοινωνήσει το μήνυμα $s_1 \in \mathbb{M}$ στον δέκτη 1 ενώ ο πομπός 2 θέλει να επικοινωνήσει το μήνυμα $s_2 \in \mathbb{M}$ στον δέκτη 2. Και τα δύο ζευγάρια πομπού-δέκτη υλοποιούνται ως νευρωνικά δίκτυα [15]. Η διαφορά έγκειται στο γεγονός ότι τα μεταδιδόμενα σήματα x_1, x_2 παρεμβάλλονται στους δέκτες ενώ προστίθεται και ο θόρυβος, οπότε προκύπτουν τα ενθόρυβα σήματα

$$y_1 = x_1 + x_2 + n_1$$

$$y_2 = x_2 + x_1 + n_2$$

όπου $n_1, n_2 \sim \mathcal{GN}(0, \beta \mathbf{I}_n)$ είναι Γκαουσιανός θόρυβος.

4.2 Τρόπος επικοινωνίας

Σε αυτή την εργασία το Multiple Inputs - Multiple Outputs τηλεπικοινωνιακό σύστημα θα περιοριστεί σε δύο πομπούς και δύο δέκτες, για χάρη της απλότητας, χωρίς αυτό να σημαίνει ότι η επέκταση σε περισσότερα ζευγάρια πομπο-δεκτών είναι δύσκολη.

Θα συγκριθούν **δύο τρόποι επικοινωνίας**. Ο πρώτος είναι η επικοινωνία όταν πομπός και δέκτης υλοποιούνται με νευρωνικά δίκτυα, δηλαδή αποτελούν έναν autoencoder. Και ο δεύτερος είναι η επικοινωνία όταν πομπός και δέκτης υλοποιούνται με παραδοσιακό hardware και χρησιμοποιούν χρονομερισμό.

Ο κάθε πομπός στέλνει στον αντίστοιχο δέκτη μια σειρά από μηνύματα $s_1, s_2, \dots, s_m \in \mathbb{M}$. Αυτά τα μηνύματα μπορεί να είναι οτιδήποτε, κείμενο, αριθμοί κ.λπ. Το ποιο μήνυμα θα στείλει ο πομπός στο δέκτη υπαγορεύεται από το χρήστη του συστήματος. Έστω ότι ο Χρήστης 1, ο οποίος χρησιμοποιεί το ζευγάρι πομπός 1 - δέκτης 1, θέλει να στείλει το μήνυμα s_1 .

Πως επικοινωνεί ο Autoencoder

Η διαδικασία που θα ακολουθήσει ο πομπός είναι η εξής. Έχει ήδη ειπωθεί ότι πομπός και δέκτης είναι νευρωνικά δίκτυα. Αρχικά ο πομπός παίρνει ολόκληρο το μήνυμα s_1 και το μετατρέπει σε μια ακολουθία από n αριθμούς. Για να γίνει πιο κατανοητό, έστω ότι το μήνυμα είναι 'γεια σας τι κάνετε' (και έστω ότι αποτελείται από $k = 4$ bits). Το νευρωνικό δίκτυο encoder (δηλαδή ο πομπός) **κωδικοποιεί** αυτό το μήνυμα σε ένα **διάνυσμα** n αριθμών (όπου n η **διάσταση** του διανύσματος). Για $n = 4$ έστω ότι το κωδικοποιεί στην ακολουθία $[0.8, -1.2, 0.5, 2.1]$. Το n είναι οι χρήσεις του καναλιού, όπως εξηγείται και εδώ [4.3](#). Αυτό σημαίνει ότι ο πομπός χρησιμοποιεί

το κανάλι τέσσερις φορές, στέλνει τέσσερα σήματα-αριθμούς, το ένα μετά το άλλο, στον αέρα, και έτσι κατάφερε να μεταδώσει το μήνυμα “γεια σας τι κάνετε”.

Από τη μεριά του το νευρωνικό δίκτυο decoder (δηλαδή ο δέκτης) περιμένει να λάβει και τους τέσσερις αριθμούς, **μαζί** με το θόρυβο και τις παρεμβολές του άλλου πομπού, ώστε να βγάλει την εκτίμησή του $\hat{s}_1$, για το μήνυμα s_1 . Στην πραγματικότητα, το διάνυσμα των τεσσάρων αριθμών αποτελεί το **σύμβολο** του αστερισμού. Το μήνυμα $s_1 = \text{“γεια σας τι κάνετε”}$ αποτυπώνεται στο IQ επίπεδο ως ένα σύμβολο. Αυτό που χρειάζεται να υπογραμμιστεί είναι ότι **κάθε σύμβολο είναι και ένα μήνυμα, το οποίο αποτελείται από n αριθμούς**.

Ο autoencoder **δεν** χρησιμοποιεί τη μέθοδο time-sharing. Ο χρονομερισμός χρησιμοποιείται σε κλασικά τηλεπικοινωνιακά συστήματα, όπου πομπός και δέκτης υλοποιούνται με το τυπικό hardware. Όταν υλοποιούνται με νευρωνικά δίκτυα η επικοινωνία που λαμβάνει χώρα δεν υιοθετεί χρονομερισμό. Αντίθετα, οι δύο πομποί στέλνουν **ταυτόχρονα** τα μηνύματα των χρηστών τους - δεν περιμένει ο ένας τον άλλο. Αυτό είναι πιο δύσκολο, διότι τα σήματα συγχρόνως στο κανάλι, παρεμβάλλονται, και οι δέκτες τα λαμβάνουν σύμφωνα με τις εξισώσεις στην ενότητα 4.1.

Ο autoencoder δημιουργεί σύμβολα τεσσάρων διαστάσεων (για το παράδειγμα $n = 4$). Αυτό σημαίνει ότι έχει στη διάθεσή του έναν τετρα-διάστατο 4D IQ χώρο για να τοποθετήσει τα σύμβολα. Αμέσως γίνεται αντιληπτή η **γεωμετρική ευρυχωρία** αυτού του χώρου έναντι του 2D IQ επιπέδου. Ο autoencoder απλώνει τα σύμβολα μακρύτερα το ένα από το άλλο, οπότε η μεταξύ τους απόσταση μεγαλώνει. Συνεπάγεται ο σχηματισμός ευνοϊκότερων **περιοχών απόφασης**, πιο διευρυμένων δηλαδή, πράγμα που σημαίνει ότι ο δέκτης θα αποκωδικοποιήσει τα σύμβολα με περισσότερη άνεση.

Πως επιτελείται η επικοινωνία με Time Sharing

Ο χρονομερισμός ή **πολυπλεξία χρόνου** (Time-Division Multiple Access (TDMA)) είναι μία κλασική μέθοδος αποφυγής παρεμβολών όταν δύο ή παραπάνω χρήστες μοιράζονται το ίδιο τηλεπικοινωνιακό κανάλι. Στο σχήμα 4.1, αν μιλήσουν ταυτόχρονα οι πομποί 1 και 2, τότε τα σήματά τους θα παρεμβληθούν στο κοινό κανάλι. Με τον χρονομερισμό ωστόσο, ο κάθε πομπός στέλνει στο δικό του **παράθυρο χρόνου**, ενώ παύει την επικοινωνία στο παράθυρο χρόνου του

άλλου πομπού. Με απλά λόγια, όταν μιλάει ο ένας, δεν γίνεται να μιλάει ο άλλος [21, κεφάλαιο 8]. Έτσι τα σήματά τους δεν συγκρούονται στο κανάλι και φτάνουν στους αντίστοιχους δέκτες δίχως παρεμβολές (φυσικά ο θόρυβος συνεχίζει να υπάρχει). Για παράδειγμα έστω ότι η επικοινωνία διαρκεί τέσσερα δευτερόλεπτα. Με τον χρονομερισμό, ο πομπός 1 θα εκπέμψει στις χρονικές στιγμές 1 και 3, ενώ ο πομπός 2 θα εκπέμψει στις χρονικές στιγμές 2 και 4. Οι εξισώσεις είναι

$$y_1 = x_1 + n_1$$

$$y_2 = x_2 + n_2$$

Με αυτό το τρόπο ο κάθε δέκτης λαμβάνει μόνο το σήμα του αντίστοιχου πομπού, συμπεριλαμβανομένου του θορύβου.

Στο παράδειγμα $(n, k) = (4, 4)$, ο κάθε πομπός πρέπει να χωρέσει το μήνυμά του σε δύο μόνο χρήσεις, αφού έχει δικαίωμα να εκπέμψει μόνο στο μισό χρόνο. Έτσι, αν το μήνυμα είναι $k = 4$ bits, τότε σε κάθε χρήση του καναλιού (από τις δύο που του αντιστοιχούν) ο πομπός πρέπει να στείλει 2 bits, να τα στριμώξει δηλαδή σε δύο χρήσεις, αντί για τέσσερις. Έτσι στέλνει δύο σύμβολα, δύο bits έκαστο. Με άλλα λόγια, η διάσταση του συμβόλου είναι $n/2$ αριθμοί.

Συγκρίνεται ο Autoencoder με την παραδοσιακή μέθοδο επικοινωνίας, η οποία διαμορφώνει τα σύμβολα σύμφωνα με τη διαμόρφωση $2^{2k/n}$ -QAM. Στο παράδειγμα $(n, k) = (4, 4)$, τα σύμβολα που στέλνει ο πομπός είναι σύμβολα που ανήκουν στη διαμόρφωση 4-QAM και χρήση χρονομερισμού. Από τα τέσσερα σύμβολα που έχει αυτή η διαμόρφωση, ο πομπός στέλνει μόνο τα δύο, για το λόγο που εξηγήθηκε στην παραπάνω παράγραφο.


Σχόλιο: Για $(1,1)$, $(2,2)$ και $(4,4)$ ο πομπός στέλνει σύμβολα 4-QAM. Για το $(4,8)$ χρησιμοποιείται διαμόρφωση 16-QAM.

Σε αυτό το σημείο όμως, χρειάζεται να τονιστούν τα **μειονεκτήματα** της μεθόδου time-sharing.

- Περιορισμός ισχύος: η κεραία που εκπέμπει τα bits έχει περιορισμένη ισχύ. Ίσως να μην καταφέρει να εκπέμψει ταυτόχρονα τα δύο αυτά bits.

- Γεωμετρία αστερισμού: τα δύο bits ισοδυναμούν με τέσσερα μηνύματα. Το κάθε μήνυμα είναι και σύμβολο. Στέλνοντας σε κάθε εκπομπή δύο bits, έχει ως αποτέλεσμα να χρειαστεί να χωρέσουν τέσσερα σύμβολα στο IQ επίπεδο, με αποτέλεσμα η μεταξύ τους απόσταση να μικραίνει. Δύο σύμβολα μπορούν να τοποθετηθούν το ένα αντιδιαμετρικά του άλλου (μέγιστη απόσταση). Τέσσερα σύμβολα τοποθετούνται βέλτιστα στις κορυφές ενός τετραγώνου. Αυτό εγχυμονεί τον κίνδυνο ανάγνωσης λανθασμένου συμβόλου από το δέκτη, ειδικά σε αστερισμούς ανώτερης τάξης.
- Θόρυβος: ο θόρυβος μετακινεί τα σύμβολα από τη θέση τους. Σε τέσσερα σύμβολα υπάρχει μεγαλύτερη πιθανότητα το ένα να πέσει επάνω στο άλλο.

4.3 Αρχιτεκτονική του συστήματος



Σχήμα 4.1: Σύστημα με δύο ζευγάρια πομπού-δέκτη που μοιράζονται κοινό κανάλι.

Στο σχήμα 4.1 φαίνονται οι δύο χρήστες, τα ζευγάρια δηλαδή πομπού-δέκτη στα οποία παρεμβάλλεται το κανάλι. Το κάθε ζεύγος είναι και ένας autoencoder ο οποίος προσπαθεί να ανακατασκευάσει στο δέκτη το αντίστοιχο μήνυμα.

Στη γενική περίπτωση, παρόλο που το κανάλι είναι κοινό, οι μεταβλητές θορύβου n_1, n_2 είναι διαφορετικές, συμβολίζοντας τη διαφορά στο hardware των δύο ζευγών. Μικρή διαφορά στο hardware συνεπάγεται και διαφορά στο θόρυβο.

Channel Uses

Ως χρήσεις καναλιού νοοείται ότι η πληροφορία σπάει για να σταλεί στον αέρα. Στέλνεται ένα σήμα s . Ο πομπός δεν το στέλνει ολόκληρο αλλά το μετατρέπει σε μία ακολουθία από n αριθμούς (διάσταση $= n$). Κάθε ένας από αυτούς τους n αριθμούς αποστέλλεται σε κάθε μία χρήση του καναλιού. Δηλαδή ο πομπός θα εκπέμψει n διαδοχικά σήματα για να μεταφέρει ένα μήνυμα. Γιατί το μήνυμα σπάει σε n αριθμούς; Λόγω εύρους ζώνης. Μπορεί να εξηγηθεί με μια μεταφορά. Έστω μια σωλήνα νερού. Μέσα από αυτή τη σωλήνα μπορεί να περάσει μόνο ένα λίτρο νερού το δευτερόλεπτο. Αν το μήνυμα είναι 100 λίτρα, τότε πρέπει να διασπαστεί σε 100 μονόλιτρα και να σταλεί το κάθε λίτρο ξεχωριστά. Έτσι σε δέκα δευτερόλεπτα θα έχουν σταλεί ολόκληρα τα 100 λίτρα. Δεν γίνεται να σταλούν τα 100 λίτρα ταυτόχρονα διότι αυτό δεν το επιτρέπει η παροχή του σωλήνα (δηλαδή το εύρος ζώνης).

4.4 Η πρόκληση της εκπαίδευσης

Στο σύστημα με δύο χρήστες είναι λιγότερο σαφές πως θα εκπαιδευθούν οι δύο autoencoders, οι οποίοι έχουν αντικρουόμενους στόχους. Ανταγωνίζονται για τη χρήση του καναλιού. Ένας τρόπος εκπαίδευσης θα ήταν να δοθεί βαρύτητα στον έναν έναντι του άλλου. Αλλά αυτό δεν προσφέρει ισότητα. Τα νευρωνικά δίκτυα που απαρτίζουν τους autoencoders πρέπει να μάθουν να εντοπίζουν το σήμα του πομπού τους και να αγνοούν το σήμα του άλλου πομπού, ενώ ταυτόχρονα να αφαιρούν και το θόρυβο. Παραδείγματος χάρη, ο δέκτης 2 λαμβάνει το σήμα

$$y_2 = x_1 + x_2 + n_2$$

όπου το σήμα x_1 προέρχεται από τον πομπό 1, οπότε πρέπει να μάθει να το αγνοεί.

Συμβολίζονται ως

$$l_1 = -\log([\hat{\mathbf{s}}_1]_{s_1})$$

$$l_2 = -\log([\hat{\mathbf{s}}_2]_{s_2})$$

οι συναρτήσεις απώλειας (cross entropy) του κάθε ζεύγους πομπού-δέκτη και $\tilde{L}_1(\theta_t)$, $\tilde{L}_2(\theta_t)$ οι απώλειες για το mini-batch t .

Μια προσέγγιση εκπαίδευσης του συστήματος 4.1 είναι η ελαχιστοποίηση του σταθμισμένου αθροίσματος των δύο απωλειών:

$$\tilde{L} = \alpha \tilde{L}_1 + (1 - \alpha) \tilde{L}_2$$

για κάποιο $\alpha \in [0, 1]$.

Ωστόσο αυτή η προσέγγιση οδηγεί σε ακραίες καταστάσεις (edge cases) διότι για $\alpha = 1$ ελαχιστοποιείται το $\tilde{L}_1$, συνεπώς ο πομπός 2 μαθαίνει να μεταδίδει ένα σταθερό σήμα, ανεξάρτητο από το s_2 , οπότε ο δέκτης 1 μπορεί απλά να το αφαιρέσει από το λαμβανόμενο σήμα $\mathbf{y}_1$. Το αντίθετο ισχύει για $\alpha = 0$. Θέτοντας το $\alpha = 0.5$ δεν προκύπτει απαραίτητα ίση απόδοση. Αντιθέτως οδηγεί σε άδικες και υποβέλτιστες λύσεις. Γί αυτό το λόγο υιοθετούνται δυναμικά βάρη α_t για κάθε mini-batch t :

$$\alpha_{t+1} = \frac{\tilde{L}_1(\theta_t)}{\tilde{L}_1(\theta_t) + \tilde{L}_2(\theta_t)}, t > 0 \quad (4.1)$$

Το βάρος α ανανεώνεται σε κάθε batch εμποδίζοντας το δίκτυο να ευνοήσει τον έναν χρήστη εις βάρος του άλλου [15].


Ο κάθε autoencoder προσπαθεί να ελαχιστοποιήσει τις $\tilde{L}_1(\theta_t)$ και $\tilde{L}_2(\theta_t)$, προκειμένου να μάθει να αναγνωρίζει το δικό του σήμα και να αγνοεί το σήμα του άλλου. Ωστόσο, οι δύο autoencoders είναι **συζευγμένοι - coupled**. Αυτό σημαίνει ότι ο κώδικας που τους υλοποιεί βλέπει την κοινή συνάρτηση απωλειών $\tilde{L}$. Κατά τη διάρκεια της εκπαίδευσης, ο Adam Optimizer αναλαμβάνει να ελαχιστοποιήσει αυτή τη συνάρτηση. Ειδικότερα, ο κάθε autoencoder, αν δρούσε αυτόνομος, απλώς θα προσπαθούσε να επιβληθεί στον άλλο, δηλαδή να ελαχιστοποιήσει τη δική του συνάρτηση απωλειών.

Η εκπαίδευση βασίζεται αποκλειστικά στα $\mathbb{M}$ μηνύματα. Όμως επειδή αυτά είναι λίγα (μόνο 16

για $k = 4$ bits), συλλέγονται 512 από αυτά, τυχαία επιλεγμένα, και τοποθετούνται σε παρτίδες (batches). Κάθε batch περιέχει 512 μηνύματα. Για 500 εποχές, ο autoencoder βλέπει σε κάθε εποχή 512 τυχαία μηνύματα. Δηλαδή συνολικά βλέπει $500 \times 512 = 256.000$ μηνύματα. Αυτά τα μηνύματα δίνονται ως είσοδο στο νευρωνικό δίκτυο encoder του πομπού, περνάνε μέσα από το κανάλι όπου και αλλοιώνονται από το θόρυβο αλλά και παρεμβάλλεται με τα 256.000 μηνύματα του άλλου πομπού, και φτάνουν στο δέκτη. Σκοπός της εκπαίδευσης είναι να μάθει ο autoencoder να ανακατασκευάζει στο δέκτη τα 256.000 μηνύματα που έστειλε ο αντίστοιχος πομπός, αφαιρώντας το θόρυβο και τις παρεμβολές.

4.5 Αστερισμοί στο επίπεδο


Σε αυτή την ενότητα παρουσιάζεται ο τρόπος με τον οποίο οι δύο autoencoders που απαρτίζουν το σύστημα 4.1 τοποθετούν τα σύμβολά τους στο IQ επίπεδο. Για να είναι δίκαιη η σύγκριση, διατηρείται ο ίδιος ρυθμός επικοινωνίας και για τον autoencoder και για τον time-sharing.



Σχήμα 4.2: Αστερισμός για το σύστημα δύο χρηστών με παραμέτρους (1,1).

Στο σχήμα 4.2 φαίνονται τα δύο σύμβολα του κάθε πομπού (κόκκινες κουκίδες για τον πομπό 1


και μαύροι σταυροί για τον πομπό 2) να παίρνουν το σχήμα του αστερισμού BPSK περιστραμμένο. Επειδή οι παράμετροι εδώ είναι $(n, k) = (1, 1)$, ο πομπός εκπέμπει μηνύματα (δηλαδή σύμβολα) του ενός bit, σε κάθε μία χρήση καναλιού. Αυτός ο μαθημένος αστερισμός (έτσι έμαθε να τοποθετεί τα σύμβολα ο κάθε πομπός, κατόπιν εκπαίδευσης) εμφανίζει ίδια επίδοση BLER με τη διαμόρφωση BPSK με time-sharing (σχήμα 4.7)



Σχήμα 4.3: Αστερισμός για το σύστημα δύο χρηστών με παραμέτρους (2,2).


Στο σχήμα 4.3 οι αστερισμοί ακολουθούν μια μορφή τύπου **super-position coding** [22]. Στη πρώτη χρήση καναλιού, ο πομπός 1 φαίνεται να διατάσσει τα σύμβολά του στον οριζόντιο άξονα ενώ ο πομπός 2 στον κάθετο. Στη δεύτερη χρήση, κάποια σύμβολα του πομπού 1 έχουν πολύ μεγάλη ενέργεια (θέσεις περίπου $(-2, -1)$ και $(2, 1)$) ενώ τα υπόλοιπα είναι πιο συμπαγώς κατανομημένα.

(c) (4,4)



Σχήμα 4.4: Αστερισμός για το σύστημα δύο χρηστών με παραμέτρους (4,4).

(d) (4,8)



Σχήμα 4.5: Αστερισμός για το σύστημα δύο χρηστών με παραμέτρους (4,8).


Για τα σχήματα 4.4 και 4.5 η ερμηνεία καθίσταται δυσκολότερη. Ωστόσο φαίνεται ότι στη πρώτη χρήση καναλιού, για παραμέτρους $(n, k) = (4, 8)$, ο πομπός 2 παρατάσσει τα σύμβολά του σε σχήμα έλλειψης.

4.6 Επίδοση BLER

Σε αυτή την ενότητα θα συγκριθεί η επίδοση BLER μεταξύ των δύο χρηστών καθώς και ενός από τους autoencoders (AE) του συστήματος 4.1 ως συνάρτηση του E_b/N_0 για τις παραμέτρους $(n, k) = \{(1, 1), (2, 2), (4, 4), (4, 8)\}$.

Χρήστης 1 vs Χρήστης 2

Θα μετρηθεί και οπτικοποιηθεί το BLER κάθε ενός από τους δύο χρήστες για να επαληθευτεί αν κυμαίνεται στα ίδια επίπεδα, δηλαδή αν το σύστημα προσφέρει ισότητα.



Σχήμα 4.6: Ανάλυση επίδοσης BLER: Χρήστης 1 εναντίον Χρήστη 2.

Πράγματι, οι δύο autoencoders έχουν πολύ παρόμοια συμπεριφορά BLER ως προς το λόγο E_b/N_0 . Συνεπώς ο τρόπος εκπαίδευσης, όπως εκφράζεται από την εξίσωση 4.1, προσφέρει ισότητα.

BLER vs E_b/N_0


Εδώ θα φανεί το BLER ενός από τους autoencoders ως συνάρτηση του E_b/N_0 για τις παραμέτρους

$(n, k) = \{(1, 1), (2, 2), (4, 4), (4, 8)\}$. Χρησιμοποιείται περιορισμός μέσης ισχύος (για όλο τον αστερισμό και όχι για κάθε σύμβολο μεμονωμένα). Ως βάση για τις συγκρίσεις χρησιμοποιείται η διαμόρφωση uncoded $2^{2k/n}$ -QAM η οποία έχει τον ίδιο ρυθμό επικοινωνίας όταν χρησιμοποιείται με time-sharing (TS) μεταξύ των δύο πομπών.

Στον πίνακα 4.1 παρουσιάζονται οι ρυθμίσεις εκπαίδευσης των autoencoders που εμφανίζονται στο σχήμα 4.7. Για να επιτευχθούν χαμηλά επίπεδα BLER χρησιμοποιείται exponential decay στον ρυθμό μάθησης, δηλαδή σταδιακή μείωσή του.

Πίνακας 4.1: Παράμετροι εκπαίδευσης των autoencoders για την κατασκευή του σχήματος 4.7.

Παράμετρος	Τιμή / Περιγραφή
Βελτιστοποιητής (Optimizer)	Adam
Αρχικός Ρυθμός Μάθησης (η)	0,002
Προγραμματισμός LR	Exponential Decay (10% ανά 1000 βήματα)
Συνάρτηση Απώλειας (Loss)	Categorical Crossentropy με Dynamic Weights (α)
Μέγεθος Batch (Batch Size)	512
SNR Εκπαίδευσης (Design E_b/N_0)	10 dB
Δείγματα Ελέγχου (N_{test})	200.000 ανά σημείο SNR
Περιορισμός Ισχύος	Average Power Constraint ($E[\ x\ ^2] = 1$)
Εποχές Εκπαίδευσης (Epochs)	Σύστημα (1,1): 200
	Σύστημα (2,2): 300
	Σύστημα (4,4): 500
	Σύστημα (4,8): 600



Σχήμα 4.7: BLER vs E_b/N_0 για τον autoencoder και το $2^{2k/n}$ -QAM time-sharing για τις παραμέτρους $(n, k) = \{(1, 1), (2, 2), (4, 4), (4, 8)\}$.

Το γράφημα του σχήματος 4.7 αποδεικνύει περίτρανα ότι ο autoencoder (4,4) νικάει τον αλγόριθμο QAM time-sharing (4,4) (το ίδιο συμβαίνει και για τον autoencoder (4,8) και τον QAM time-sharing (4,8)). Μάλιστα, όπως φαίνεται στα 6dB, ο autoencoder (κόκκινη διακεκομμένη) νικάει κατά μία ολόκληρη τάξη μεγέθους (10^{-3} έναντι 10^{-2}).

Ο λόγος είναι ότι η βαθιά μάθηση κατάφερε καλύτερα και πιο αποδοτικά να εκπαιδεύσει το σύστημα επικοινωνίας με δύο ζευγάρια πομπών-δεκτών με κοινό κανάλι επικοινωνίας ώστε να παρουσιάζει καλύτερη επίδοση BLER από ότι ο αλγόριθμος time-sharing.

Κεφάλαιο 5

Radio Transformer Networks (RTNs)

Σε αυτό το κεφάλαιο το απλό μοντέλο του Autoencoder θα **ενισχυθεί** εισάγοντας έτοιμη γνώση, κάνοντάς το ουσιαστικά εξυπνότερο. Αυτό θα δώσει αρκετά πλεονεκτήματα. Ουσιαστικά η βαθιά μάθηση επεκτείνεται, ενσωματώνοντας σημαντικές πληροφορίες. Αντί να λύσει το πρόβλημα χωρίς καμία πληροφορία, της παρέχεται γνώση. Το σημαντικότερο πλεονέκτημα αυτής της μεθοδολογίας είναι η ταχύτερη σύγκλιση.


5.1 Ενσωμάτωση ειδικής γνώσης

Η γνώση που παρέχεται στο μοντέλο βαθιάς μάθησης αποκαλείται **ειδική γνώση πεδίου** (domain expert knowledge) [23, 24]. Αυτό δίνει μια πρώτη εικόνα στον autoencoder για το πρόβλημα προς επίλυση, δηλαδή δεν ξεκινάει από το μηδέν, χωρίς καθόλου γνώσεις. Ο autoencoder που χρησιμοποιεί την τεχνική RTN έχει **καλύτερη επίδοση** από τον απλό autoencoder. Ένα ακόμη πλεονέκτημα του RTN είναι η **ταχύτερη σύγκλιση**.

Θεωρητικά δεν υπάρχει τίποτα που να μπορεί να κάνει ο RTN-autoencoder το οποίο να μην μπορεί να κάνει ο απλός autoencoder, ωστόσο ο πρώτος, έχοντας την γνώση πεδίου, απλοποιεί το χώρο αναζήτησης και βελτιώνει την γενίκευση (έννοιες καίριες στη μηχανική μάθηση). Στην ουσία η ενσωμάτωση γνώσης πεδίου στο νευρωνικό δίκτυο πρόσκειται στο πεδίο του **Informed Machine Learning** [25].

5.2 Αρχιτεκτονική RTN

Ένας τυπικός δέκτης υλοποιημένος ως δίκτυο RTN φαίνεται στο σχήμα 5.1.



Σχήμα 5.1: Δέκτης υλοποιημένος ως δίκτυο RTN.

Όπως φαίνεται στο σχήμα 5.1, η είσοδος $\mathbf{y}$ αρχικά περνάει από το δίκτυο εκτίμησης παραμέτρων $g_{\omega}(\mathbf{y})$, έπειτα εφαρμόζεται ένας γνωστός παραμετρικός μετασχηματισμός $t(\mathbf{y}, \omega)$ για να παραχθεί το κανονικοποιημένο σήμα $\bar{\mathbf{y}}$ και τέλος αυτό το σήμα κατηγοριοποιείται στο δίκτυο $g(\bar{\mathbf{y}})$ για να παραχθεί η έξοδος $\hat{s}$.

Να σημειωθεί ότι μονάχα ο δέκτης υλοποιείται ως δίκτυο RTN και το σήμα $\mathbf{y}$ είναι το σήμα που προκύπτει από το κανάλι του σχήματος 3.3.


5.3 Πρόβλημα ισοστάθμισης σε πολυδιαδρομικά κανάλια

Πολυδιαδρομικό κανάλι


Στην πραγματικότητα, όταν ένας πομπός στέλνει ένα σήμα, αυτό δεν ταξιδεύει μόνο σε ευθεία γραμμή προς το δέκτη (line of sight). Αντιθέτως, το σήμα αποστέλλεται από την κεραία του πομπού προς όλες τις κατευθύνσεις, προσκρούει στο περιβάλλον, σε κτήρια, βουνά κτλ., φτάνοντας στο δέκτη από πολλές διαφορετικές διαδρομές. Έτσι, ο δέκτης λαμβάνει πολλά **αντίγραφα** (copies) του ίδιου σήματος (αντανακλάσεις), καθένα από διαφορετική διαδρομή. Ως εκ τούτου, τα αντίγραφα φτάνουν στο δέκτη σε διαφορετικές χρονικές στιγμές (επειδή προφανώς οι διαδρομές έχουν διαφορετικό μήκος).

Ηχώ

Τα καθυστερημένα αντίγραφα του σήματος, τα οποία δημιουργούνται εξαιτίας των αντανακλάσεων του πολυδιαδρομικού καναλιού, αποκαλούνται **ηχώ**. Αυτές οι ηχώ αλληλεπιδρούν στο δέκτη. Αν φτάσουν σε φάση (συμφασικές) τότε προκαλούν ενίσχυση του σήματος. Αν φτάσουν σε διαφορετικές φάσεις, τότε ακυρώνουν το σήμα (deep fade). Η κατανομή Rayleigh είναι η στατιστική κατανομή που περιγράφει πόσο ισχυρό ή ασθενές θα είναι το σήμα σε περιβάλλον με αντανακλάσεις (σχήματα 5.2, 5.3).



Σχήμα 5.2: Πολυδιαδρομικό κανάλι σε θάλασσα.



Σχήμα 5.3: Πολυδιαδρομικό κανάλι σε αστικό περιβάλλον.

Διασυμβολική παρεμβολή

Η **διασυμβολική παρεμβολή** (Inter-Symbol Interference - ISI) είναι το πρόβλημα που εμφανίζεται όταν αποστέλλονται πολλά bits και, λόγω των ηχώ (δηλαδή των αντανακλάσεων), το ένα bit πέφτει πάνω στο άλλο*. Έτσι το απεσταλμένο μήνυμα μπερδεύεται [26, κεφάλαιο 9].

*Αν κανείς μιλήσει μέσα σε ένα σπήλαιο, τότε οι λέξεις του, λόγω των ηχώ, θα πέσουν η μία πάνω στην άλλη και θα ανακατευτούν. Αυτό είναι ένα παράδειγμα διασυμβολικής παρεμβολής.

Taps

Τα **taps** είναι σημεία καθυστέρησης. Αν ένα σήμα φτάσει στο δέκτη καθυστερημένο, τότε αυτό είναι ένα tap. Παραδείγματος χάρη, ένα κανάλι με τρία taps σημαίνει τα εξής: ο δέκτης λαμβάνει το κανονικό σήμα (ένα tap, χωρίς καθυστέρηση), μια ηχώ με μικρή καθυστέρηση (δεύτερο tap) και μια με μεγαλύτερη (τρίτο tap).

Στέλνεται το σήμα $x[n]$ και λαμβάνεται το $y[n]$:

$$y[n] = h_0x[n] + h_1x[n - 1] + h_2x[n - 2]$$

όπου h τα βάρη των taps, δηλαδή οι συντελεστές Rayleigh.

Το αυθεντικό σήμα $x[n]$ παρεμβάλλεται από τις ηχώ $x[n - 1]$, $x[n - 2]$ (διασυμβολική παρεμβολή).

Κάθε tap είναι ένας μιγαδικός αριθμός $h = \alpha + jb$, όπου α και b ακολουθούν κανονική κατανομή.

Ισοστάθμιση (Equalization)

Αφού λοιπόν οι ηχώ προκαλούν παραμόρφωση στο λαμβανόμενο σήμα, πρέπει με κάποιον τρόπο να αντιμετωπιστούν. Η αντιμετώπισή τους ονομάζεται **ισοστάθμιση** ([26, ενότητα 9.4]). Η ισοστάθμιση προσφέρει απαλλαγή από τις ηχώ και πλέον το σήμα βρίσκεται στην αρχική του μορφή, αυτήν με την οποία εκπέμφθηκε. Το τμήμα του δέκτη που χρησιμοποιείται για την ισοστάθμιση ονομάζεται ισοσταθμιστής. Υπάρχουν διάφοροι τύποι ισοσταθμιστών [26, ενότητα 9.4]:


1. Γραμμικός ισοσταθμιστής.
2. Ισοσταθμιστής Επιβολής Μηδενισμών Zero Forcing (ZF): Αν το κανάλι είναι H , τότε ο δέκτης εφαρμόζει το φίλτρο $1/H$ για να λάβει το καθαρό σήμα x . Το πρόβλημα με αυτή τη μέθοδο είναι ότι η αντιστροφή ενός κακού καναλιού συχνά συνεπάγεται ενίσχυση θορύβου.
3. Ισοσταθμιστής Ελάχιστου Μέσου Τετραγωνικού Σφάλματος.
4. Μη-Γραμμικοί ισοσταθμιστές.

Σημείωση: Χωρίς ισοστάθμιση δεν μπορεί να διαχωριστεί το αρχικό σήμα από τις ηχώ του.

Διαλείψεις Rayleigh

Οι διαλείψεις είναι η μεταβολή του σήματος λόγω των ανακλάσεων. Άλλοτε τα σήματα είναι συμφασικά και προστίθενται, άλλοτε έρχονται με διαφορά φάσης, οπότε αλληλο-ακυρώνονται.

Η **κατανομή Rayleigh** (σχήμα 5.4) είναι μια στατιστική κατανομή που χρησιμοποιείται όταν δεν υπάρχει οπτική επαφή (non line of sight) μεταξύ πομπού και δέκτη, για να μοντελοποιήσει τις ανακλάσεις του σήματος [27].



Σχήμα 5.4: Κατανομή Rayleigh.

RTN vs απλός Autoencoder

Ενώ ο απλός autoencoder πρέπει να ανακαλύψει μόνος του αν υπάρχει διασυμβολική παρεμβολή και πως να εκτελέσει ισοστάθμιση, το δίκτυο RTN το γνωρίζει εξ αρχής, διότι ο σχεδιαστής του συστήματος του το καθιστά γνωστό μέσω της αρχιτεκτονικής του. Για να γίνει πιο κατανοητό, ο παραμετρικός μετασχηματισμός $t(\mathbf{y}, \omega)$ του σχήματος 5.1 αφορά την επονομαζόμενη ειδική γνώση πεδίου. Ουσιαστικά, μοντελοποιεί την ισοστάθμιση. Γι' αυτό απλοποιείται ο χώρος αναζήτησης (search space) και η μάθηση επιταχύνεται. Το αποτέλεσμα είναι η **ταχύτερη σύγκλιση**.

5.4 Αποτελέσματα

Το πείραμα


Το πείραμα που θα εκτελεστεί είναι η μέτρηση της επίδοσης BLER σε πολυδιαδρομικό κανάλι με $L = 3$ taps. Θα συγκριθούν οι επιδόσεις ενός autoencoder(8,4) με και χωρίς RTN.

Αστερισμοί

Για να γίνει αντιληπτός ο τρόπος με τον οποίο ο θόρυβος και οι διαλείψεις Rayleigh επηρεάζουν το σήμα, θα οπτικοποιηθούν (με χρήση t-SNE [28]) οι αστερισμοί των εξής σημάτων:

- το σήμα $\mathbf{x}$, το οποίο προκύπτει στην έξοδο του πομπού του σχήματος 3.3,
- το σήμα $\mathbf{y}$, ακριβώς μετά την έξοδο του καναλιού του ίδιου σχήματος, και
- το σήμα $\bar{\mathbf{y}}$, αφότου περάσει από τον παραμετρικό μετασχηματισμό του σχήματος 5.1

Οι αστερισμοί προέκυψαν για θόρυβο 15 dB, στις 150 εποχές.



Σχήμα 5.5: Αστερισμοί για τα σήματα $\mathbf{x}$, $\mathbf{y}$, $\bar{\mathbf{y}}$.

Το σχήμα 5.5 είναι ο καλύτερος τρόπος κατανόησης του τρόπου με τον οποίο οι διαλείψεις και ο θόρυβος του καναλιού αλλοιώνουν το σήμα. Στο σχήμα A φαίνεται το σήμα $\mathbf{x}$, έτσι όπως βγήκε από τον πομπό. Φαίνονται διακριτά σύμβολα, τέλεια διαχωρισμένα μεταξύ τους. Όμως στο B αποτυπώνεται το σήμα $\mathbf{y}$: εδώ φαίνεται η καταστροφική για το σήμα επίδραση του καναλιού. Είναι μια σούπα από σύμβολα, μπερδεμένα μεταξύ τους. Αυτό είναι χαρακτηριστικό παράδειγμα διασυμβολικής παρεμβολής, το ένα σύμβολο μπερδεύεται με το άλλο. Στο τέλος, στο Γ, υπάρχουν **νησίδες συμβόλων (clusters)**. Αυτό είναι αποτέλεσμα της εφαρμογής στο σήμα $\mathbf{y}$ του παραμετρικού μετασχηματισμού $t(\mathbf{y}, \omega)$. Αυτός ο μετασχηματισμός διαχώρισε τα σύμβολα, οπότε αυτό θα βοηθήσει πολύ τον δέκτη στο διαχωρισμό των συμβόλων στα τελικά μηνύματα.

Αποτελέσματα σε πολλές και λίγες εποχές

Όπως αναφέρει και το paper, όταν οι εποχές είναι πολλές και τα νευρωνικά δίκτυα των encoders/decoders πλατύτερα, τότε η διαφορά στην απόδοση μεταξύ απλού και RTN autoencoder μειώνεται.


Προτού παρατεθούν τα γραφήματα, αξίζει να τονιστούν οι διαφορές στην αρχιτεκτονική των δικτύων όταν οι εποχές είναι 300 και 600. Ουσιαστικά το ζητούμενο είναι στις 300 εποχές τα νευρωνικά δίκτυα να είναι στενότερα και στις 600 πλατύτερα. Αυτό είναι απαραίτητο για να διερευνηθεί ο ισχυρισμός των συγγραφέων του paper [15] ότι 'η απόδοση μεταξύ απλού autoencoder και autoencoder RTN μικραίνει όταν τα δίκτυα των encoder-decoder φτιάχνονται πλατύτερα και εκπαιδεύονται για περισσότερες επαναλήψεις'.

1. 300 εποχές: το νευρωνικό δίκτυο του πομπού (encoder) έχει 256 νευρώνες στο πρώτο κρυφό επίπεδο (με συνάρτηση ενεργοποίησης ReLU) και 128 στο δεύτερο (ReLU). Το ίδιο ισχύει και στο νευρωνικό δίκτυο του δέκτη (decoder) του απλού autoencoder. Στον RTN autoencoder, η αρχιτεκτονική αφορά το νευρωνικό δίκτυο του ταξινομητή (το τελευταίο επίπεδο - discriminative network). Έχει 256 νευρώνες ο πρώτος και 128 ο δεύτερος κρυφός νευρώνας.
2. 600 εποχές. Ισχύουν τα ίδια, απλώς το πρώτο κρυφό επίπεδο έχει 512 νευρώνες ενώ το δεύτερο 256.


Πρέπει να σημειωθεί ότι, ανεξαρτήτως 300 ή 600 εποχών, το νευρωνικό δίκτυο του εκτιμητή παραμέτρων (parameter estimation) περιέχει 128 νευρώνες στο πρώτο κρυφό επίπεδο και 64 στο δεύτερο. Αυτό συμβαίνει διότι ο εκτιμητής παραμέτρων εκτελεί παλινδρόμηση (regression) 6 παραμέτρων ($L = 3$ taps, με κάθε tap να είναι ένας μιγαδικός αριθμός - άρα δύο πραγματικοί αριθμοί), μια πιο απλή μαθηματική πράξη από την ταξινόμηση $M = 16$ κλάσεων, άρα δεν χρειάζεται και τόσους νευρώνες.

Οι autoencoders με και χωρίς RTN θα συγκριθούν με τη διαμόρφωση DBPSK(8,7), η οποία χρησιμοποιεί τον κώδικα διόρθωσης σφαλμάτων Hamming(7,4). Αποστέλλονται $k = 4$ bits. Ο κώδικας διόρθωσης Hamming προσθέτει ακόμη τρία bits ισοτιμίας και φτιάχνει μια λέξη των 7 bits. Για να δουλέψει η διαμόρφωση **διαφορικής δυαδικής ολίσθησης φάσης** (Differential-BPSK) πρέπει να προσθέσει ακόμη ένα bit, δηλαδή στα $k = 7$ bits του Hamming προσθέτει ακόμη ένα και εκπέμπει $n = 8$ bits. Άρα συνολικά, οι autoencoders και η διαμόρφωση DBPSK παίρνουν

τα $k = 4$ bits πληροφορίας και εκπέμπουν $n = 8$ σύμβολα στο κανάλι, εξού και η σημειογραφία $(n, k) = (8, 4)$ και $(n, k) = (8, 7)$ αντίστοιχα.




Σχήμα 5.6: Καμπύλες BLER που συγκρίνει την επίδοση των τριών διαφορετικών μεθόδων (στις 300 εποχές).



Σχήμα 5.7: Καμπύλες BLER που συγκρίνει την επίδοση των τριών διαφορετικών μεθόδων (στις 600 εποχές).

Η βασική παρατήρηση που προκύπτει από τα σχήματα 5.6 και 5.7 είναι ότι απλός και RTN autoencoder έχουν καλύτερη απόδοση από το σχήμα διαμόρφωσης DBPSK(8,7), εκτός από τα 20 και 18 dB και έπειτα. Από ότι φαίνεται, η βαθιά μάθηση ξεπερνά τον παραδοσιακό αλγόριθμο εκτός από την περίπτωση πολύ ισχυρού σήματος (πάνω από 20 και 18 dB αντίστοιχα). Όταν το σήμα είναι πολύ ισχυρό τότε δουλεύει εξίσου καλά και ο παραδοσιακός αλγόριθμος. Λογικό, αφού όταν δεν υπάρχει θόρυβος, όπερ το SNR είναι πολύ μεγάλο, τότε ο παραδοσιακός αλγόριθμος DBPSK + Hamming δουλεύει εξίσου καλά. Όμως σε περιοχές μεσαίου SNR η βαθιά μάθηση είναι ο απόλυτος νικητής.

Τώρα θα παρουσιαστεί κάτι εξαιρετικό, το οποίο αποτυπώνει την διαφορά στην απόδοση του απλού autoencoder και του RTN autoencoder, σε μορφή ραβδογράμματος. Πρόκειται για το **χάσμα επίδοσης**.



Σχήμα 5.8: Χάσμα επίδοσης σε μορφή ραβδογράμματος.

Η ερμηνεία αυτού του ραβδογράμματος έχει ως εξής. Καταρχάς στον κατακόρυφο άξονα διακρίνεται η διαφορά στο BLER (απλός AE - RTN AE). Αυτό σημαίνει ότι για θετική διαφορά, το RTN έχει καλύτερη επίδοση (έκανε λιγότερα λάθη από τον απλό AE) και για αρνητική διαφορά, χειρότερη (έκανε περισσότερα λάθη). Οι κόκκινες ράβδοι αφορούν στενούς AE εκπαιδευμένους σε 300 εποχές, ενώ οι μπλε ράβδοι πλατιούς AE εκπαιδευμένους σε 600 εποχές.

Ανάλυση ανά περιοχή:

- 0-5 dB: ο θόρυβος είναι πολύ ισχυρός, το σήμα ασθενές. Οι autoencoders απλά μαντεύουν. Στα 0 dB ο απλός AE έκανε λιγότερα λάθη από τον RTN AE, ενώ στα 5 dB το αντίθετο. Αυτό το αποτέλεσμα δεν έχει ιδιαίτερη αξία, μια και το BLER σε αυτή τη περιοχή του E_b/N_0 είναι ούτως ή άλλως πολύ υψηλό, και για τους δύο AE.
- 10-15 dB: Στα 10 dB (όπου το σήμα είναι ισχυρό αλλά όχι τόσο όσο στα 20 dB) η κόκκινη ράβδος είναι πανύψηλη. Αυτό σημαίνει ότι ο RTN AE νίκησε με διαφορά. Λογικό, αφού ο απλός AE δεν έχει την ιδιαίτερη αρχιτεκτονική του RTN AE με τον εκτιμητή παραμέτρων και

τον παραμετρικό μετασχηματισμό. Από την άλλη, η μπλε ράβδος είναι μικρή. Αυτό σημαίνει ότι αν πλατύνει ο απλός AE, και εκπαιδευθεί σε διπλάσιες εποχές (600 έναντι 300), τότε θα καταφέρει να λύσει το πρόβλημα της διασυμβολικής παρεμβολής εξίσου καλά με τον RTN AE. **Το χάσμα μειώθηκε δραματικά.**


Στα 15 dB το σήμα είναι αρκετά ισχυρό, για να μπορέσει εξίσου καλά και ο απλός AE να λύσει το πρόβλημα.

- 20 dB: το σήμα είναι πεντακάθαρο. Η διαφορά είναι μεν αμελητέα, αλλά κερδίζει ο RTN AE, ειδικά στα πλατιά δίκτυα (μπλε ράβδος). Αυτό συμβαίνει επειδή ο απλός AE, έχοντας τόσο πλατιά αρχιτεκτονική, δυσκολεύεται να γενικεύσει (**overfitting**), ενώ ο RTN λόγω της ενσωματωμένης γνώσης του καναλιού, τα πηγαίνει καλύτερα.

Αυτό αποδεικνύει και τον ισχυρισμό του paper [15], ότι η διαφορά στην απόδοση μεταξύ απλού και RTN AE μειώνεται όταν τα δίκτυα του πομπού και του δέκτη κατασκευάζονται πλατύτερα και εκπαιδεύονται για περισσότερες εποχές.

Ταχύτητα σύγκλισης

Όπως ειπώθηκε, ο autoencoder RTN έχει ταχύτερη σύγκλιση από τον απλό autoencoder. Στο παρακάτω γράφημα 5.9 διαφαίνεται ξεκάθαρα η υπεροχή του RTN AE έναντι του απλού AE. Όχι μόνο νικάει σε επίδοση, αλλά και συγκλίνει ταχύτερα, αφού η κόκκινη καμπύλη (RTN) ήδη από τις 20 εποχές, ενώ η μπλε μετά τις 40.



Σχήμα 5.9: Training loss.

Κεφάλαιο 6

Ταξινόμηση διαμόρφωσης με χρήση CNN

Το τελευταίο κεφάλαιο πραγματεύεται την **ταξινόμηση διαμόρφωσης** (modulation classification) μέσω της ‘ανάγνωσης’ IQ δειγμάτων. Είναι σαν ένας δέκτης ο οποίος διαβάζει IQ δείγματα και αποφασίζει ποια είναι η χρησιμοποιούμενη διαμόρφωση. Τα CNN επιδεικνύουν εντυπωσιακά αποτελέσματα στους τομείς της αναγνώρισης εικόνας και υπολογιστικής όρασης [29]. Μένει να εξακριβωθεί εάν παρέχουν εξίσου ικανοποιητικά αποτελέσματα και στις τηλεπικοινωνίες. Αυτός είναι ο σκοπός του παρόντος κεφαλαίου.

6.1 Το πρόβλημα

Μέχρι πρότινος, οι μηχανικοί βασίζονταν στην (χειροκίνητη) εξαγωγή ειδικών χαρακτηριστικών (expert features) ενός σήματος, δηλαδή στατιστικές ιδιότητες. Παραδείγματα τέτοιων ειδικών χαρακτηριστικών αποτελούν ροπές ανώτερης τάξης (4ης και 6ης), κυκλοστατικά χαρακτηριστικά, στιγμιαία χαρακτηριστικά κ.α [30, 31]. Η παραδοσιακή μέθοδος παρέχει ως είσοδο αυτά τα χαρακτηριστικά σε αλγόριθμους μηχανικής μάθησης, παραδείγματος χάρι δέντρα απόφασης (decision trees), διανύσματα υποστήριξης (support vectors), τυχαία δάση (random forests) και νευρωνικά δίκτυα πρόσθιας τροφοδότησης (feedforward NNs).

Η χρήση συνελικτικών νευρωνικών δικτύων (CNNs) αλλάζει το τοπίο. Συγκεκριμένα λαμβάνει ωμά δεδομένα χρονοσειρών ραδιοσυχνοτήτων (raw time-series data) των 128 IQ δειγμάτων (δηλαδή διαστάσεων 2×128) και αναγνωρίζει μόνο του τα μοτίβα, δηλαδή την χρησιμοποιούμενη διαμόρφωση, αφότου εκπαιδευθεί. Το συνελικτικό νευρωνικό δίκτυο δεν βλέπει τις διαμορφώσεις ως εικόνες, αλλά μαθαίνει τα χαρακτηριστικά (**feature learning**) των μετρήσεων των IQ δειγμάτων.

Πως λειτουργεί το CNN

Η είσοδος του νευρωνικού CNN, όπως φαίνεται και στο πίνακα 6.1, είναι ένας πίνακας διαστάσεων 2×128 , δηλαδή έχει δύο γραμμές και 128 στήλες. Η πρώτη γραμμή αφορά τις 128 μετρήσεις της συμφασικής συνιστώσας και η δεύτερη γραμμή τις 128 μετρήσεις της κάθετης συνιστώσας.

Ο πομπός εκπέμπει στον αέρα σήματα. Ο δέκτης, για να τα επεξεργαστεί, παίρνει στιγμιότυπα αυτών των σημάτων. Αυτά τα στιγμιότυπα αποκαλούνται **δείγματα** (samples). Κάθε δείγμα είναι ένας μιγαδικός αριθμός, όπου **I** το πραγματικό μέρος και **Q** το φανταστικό του μέρος. Προσοχή: τα δείγματα IQ **δεν** αποτελούν σύμβολα του IQ επιπέδου, διότι ο πομπός δεν στέλνει το σύμβολο αυτό καθ' αυτό αλλά ένα σήμα που προκύπτει από την διέλευση του συμβόλου μέσω ενός φίλτρου.

Ειδικότερα, το σήμα που εκπέμπει ο πομπός μεταδίδεται στον αέρα με τη μορφή

$$s(t) = I(t)\cos(2\pi f_c t) - Q(t)\sin(2\pi f_c t)$$

Ο δέκτης με τη σειρά του διαβάζει το σήμα

$$y(t) = I(t) + jQ(t)$$

όπου $I(t)$ το πραγματικό και $Q(t)$ το φανταστικό μέρος της πληροφορίας.

Το νευρωνικό δίκτυο CNN παρατηρεί αυτά τα δείγματα και μαθαίνει τα χαρακτηριστικά τους. Ως επιβλεπόμενη μάθηση, εκπαιδεύεται σε 220.000 δείγματα τα οποία αντιστοιχούν σε γνωστή **ετικέτα** (label), δηλαδή το κάθε δείγμα είναι γνωστό σε ποια διαμόρφωση ανήκει. Έτσι με τη

διαδικασία της εκπαίδευσης και του αλγορίθμου backpropagation, το CNN μαθαίνει να **κατηγοριοποιεί άγνωστα δείγματα IQ σε διαμορφώσεις**.

Ειδικά χαρακτηριστικά (expert features)

Για κάθε παράθυρο 128 μετρήσεων, εξάγονται 16 ειδικά χαρακτηριστικά. Αντί ο τηλεπικοινωνιακός μηχανικός να δώσει στους αλγορίθμους $2 \times 128 = 256$ μετρήσεις, υπολογίζει 16 πιο ειδικά νούμερα. Αυτά είναι η μέση τιμή (mean), η τυπική απόκλιση (standard deviation), η ασυμμετρία (skewness) και η κύρτωση (kurtosis) για καθένα από τα ωμά δείγματα I, Q, το πλάτος και τη φάση.

Για παράδειγμα, παίρνει το διάνυσμα των 128 μετρήσεων για το **I**. Υπολογίζει μέση τιμή (έστω 0.8), τυπική απόκλιση (έστω 0.6) και τα λοιπά. Στο τέλος αντί για τον πίνακα 2×128 έχει 16 νούμερα, τα οποία αποτελούν και έναν πιο **συμπαγή χώρο χαρακτηριστικών** (compact feature space).

Τα ειδικά χαρακτηριστικά αποτυπώνουν τη συμπεριφορά των φυσικών σημάτων. Μια τιμή, παραδείγματος χάρη, της ασυμμετρίας, δείχνει μια συγκεκριμένη διαμόρφωση. Τα ειδικά χαρακτηριστικά, λοιπόν, αποτελούν ένα είδος από στατιστικό σκονάκι για να μαντέψει σωστά το δέντρο απόφασης. Τα ειδικά χαρακτηριστικά αποτελούν τη **στατιστική ταυτότητα** του σήματος και έχουν σχέση με τη τελική διαμόρφωση.

6.2 Το dataset RadioML 2016.10A

Το σύνολο δεδομένων που χρησιμοποιείται είναι το RadioML 2016.10A [32]. Αποτελείται από:

- 220.000 δείγματα.
- Ο δέκτης ακούει το κάθε ένα από τα 220.000 δείγματα για μικρό χρονικό διάστημα. Έτσι, σε κάθε δείγμα εκτελεί 128 μετρήσεις (αυτό είναι το **παράθυρο παρατήρησης**, πόσες μετρήσεις εκτελεί σε κάθε δείγμα). Για την ακρίβεια, λαμβάνει 128 μετρήσεις για την συμφασική (In-phase) και 128 για την κάθετη (Quadrature) συνιστώσα.

- 11 διαμορφώσεις. 8 ψηφιακές (BPSK, QPSK, 8PSK, 16-QAM, 64-QAM, GFSK, CPFSK, PAM4) και 3 αναλογικές (AM-DSB, AM-SSB, WBFM).

Το νευρωνικό δίκτυο, στην έξοδό του, θα μαντέψει σε ποια από αυτές τις διαμορφώσεις ανήκει το κάθε δείγμα. Εφαρμόζοντας τον κανόνα 80%-20%, τα 220.000 δείγματα χωρίζονται σε:

1. **Σύνολο εκπαίδευσης:** το νευρωνικό θα εκπαιδευτεί σε 176.000 δείγματα.
2. **Σύνολο ελέγχου:** ο έλεγχος του νευρωνικού θα γίνει σε αυτά τα 44.000 δείγματα. Δεν θα δει αυτά τα δείγματα κατά τη διάρκεια της εκπαίδευσης.

Τα δείγματα έχουν περάσει μέσα από ασύρματο κανάλι και έχουν υποστεί ρεαλιστικές επιδράσεις θορύβου και πολυδιαδρομική εξασθένιση. Επίσης, δειγματολήφθηκαν σε 20 διαφορετικές τιμές SNR, στο διάστημα -20 έως 18 dB.

6.3 Αρχιτεκτονική του CNN νευρωνικού δικτύου

Το συνελικτικό νευρωνικό δίκτυο έχει τη δομή του πίνακα 6.1. Για να αποφευχθεί το φαινόμενο της υπερεκπαίδευσης (overfitting), προστέθηκαν Dropout επίπεδα. Dropout(0.5) (αντίστοιχα για το Dropout(0.25)) σημαίνει ότι σε κάθε εποχή απενεργοποιούνται το 50% των νευρώνων, ώστε να αναγκαστεί το νευρωνικό να γενικεύσει και όχι να απομνημονεύσει το θόρυβο. Ακόμη, προστέθηκε και early stopping, το οποίο σταματάει να εκπαιδεύει το δίκτυο όταν σταματήσει να βελτιώνεται η απόδοσή του στην ταξινόμηση. Ταυτόχρονα αποθηκεύει το καλύτερο μοντέλο.

Αξίζει να τονιστεί ότι τα επίπεδα Dropout(0.25) προστέθηκαν μετά από τα συνελικτικά (Convolution) επίπεδα διότι δεν περιέχει τόσα βάρη, όσα το πλήρως συνδεδεμένο (Dense) επίπεδο, οπότε το 25% των νευρώνων αρκεί να απενεργοποιηθεί ώστε το δίκτυο να ανακαλύψει εύρωστες μεθόδους γενίκευσης και αποφυγής υπερεκπαίδευσης. Στα πλήρως συνδεδεμένα επίπεδα, τα οποία περιέχουν σαφώς περισσότερα βάρη, προστέθηκαν επίπεδα Dropout(0.5) ώστε να αντιμετωπιστεί ισχυρότερα η υπερεκπαίδευση.

Πίνακας 6.1: Αρχιτεκτονική του CNN για ταξινόμηση διαμόρφωσης με 324.363 παραμέτρους.

Layer	Output Dimensions
Input	2×128
Convolution (128 filters, size 2×8) + ReLU	128×121
Max Pooling (size 2, strides 2)	128×60
Dropout (0.25)	128×60
Convolution (64 filters, size 1×16) + ReLU	64×45
Max Pooling (size 2, strides 2)	64×22
Dropout (0.25)	64×22
Flatten	1408
Dense + ReLU	128
Dropout (0.5)	128
Dense + ReLU	64
Dropout (0.5)	64
Dense + ReLU	32
Dense + softmax	11

6.4 Δένδρα Απόφασης

Τα δένδρα απόφασης αποτελούν έναν απλό και εύληπτο αλγόριθμο μηχανικής μάθησης που ανήκουν στη κατηγορία της επιβλεπόμενης μάθησης. Λειτουργούν ακριβώς σαν ένα δένδρο με κλαδιά και μπορεί να θεωρηθεί σαν διάγραμμα ροής.

Ένα **single tree** είναι ένα απλό δέντρο απόφασης που υλοποιείται με τη βιβλιοθήκη scikit-learn [33]. Ξεκινάει από την κορυφή και κάνει ερωτήσεις του τύπου “Είναι η κύρτωση μεγαλύτερη από 2.3”. Αν ναι, πηγαίνει αριστερά (αριστερό κλαδί), αν όχι, πηγαίνει δεξιά (δεξί κλαδί) (τυχαίο παράδειγμα). Στο τέλος καταλήγει σε ένα φύλλο όπου λαμβάνεται η τελική απόφαση, π.χ. αν ισχύουν αυτά, αυτά και αυτά, τότε η διαμόρφωση είναι η 16-QAM (τυχαίο παράδειγμα).

Το single tree απέτυχε στη περίπτωση των ωμών δειγμάτων, διότι δεν μπορεί να κάνει ερωτήσεις σε 128 τυχαίες τιμές και να λάβει αξιόπιστο αποτέλεσμα. Οι 128 τιμές δεν έχουν φυσικό νόημα.

Το **boosted tree** είναι μια ομάδα από 1000 δέντρα (δηλαδή χίλιοι εκτιμητές, estimators), που χρησιμοποιούν τον αλγόριθμο extreme gradient boosting (XGBoost) [34]. Δουλεύει δημιουργώντας και εκπαιδεύοντας δέντρα, με κάθε επόμενο δέντρο να διορθώνει αποκλειστικά τα λάθη του προηγούμενου δέντρου. Έτσι φτιάχνει μια επιτροπή (έτσι λέγεται στη μηχανική μάθηση, committee) από 1000 δέντρα, τα οποία είναι εκπαιδευμένα και έτοιμα να αποφασίσουν για τη χρησιμοποιούμενη διαμόρφωση όταν λάβουν τα 16 ειδικά χαρακτηριστικά. Γι' αυτό στο σχήμα 6.2 το boosted tree υπερσχύει του CNN (μετά τα 5 dB).

6.5 Αποτελέσματα


Σε αυτή την ενότητα παρουσιάζονται τα αποτελέσματα των πειραμάτων, τα οποία είναι γραφήματα συγκρίσεων μεταξύ των ταξινομητών καθώς και ένας πίνακας σύγκυσης.

6.5.1 Σύγκριση Ταξινομητών

Θα συγκριθεί η ακρίβεια ταξινόμησης του συνελικτικού νευρωνικού δικτύου CNN με αυτή των ταξινομητών δένδρων απόφασης Single Tree και Boosted Tree. Το Boosted Tree περιλαμβάνει 1000 εκτιμητές, ενώ το Single Tree λειτουργεί σε μια μίξη 16 ειδικών χαρακτηριστικών (analog and cumulant expert features). Θα πραγματοποιηθούν και πειράματα στα οποία τα Boosted και Single Trees θα δουλεύουν επάνω στα ωμά (raw) IQ δείγματα. Έτσι, θα φανεί εάν το CNN είναι σε όλες τις περιπτώσεις και συνθήκες καλύτερο ή όχι.

Ωμά IQ δείγματα

Από την παρατήρηση του σχήματος 6.1 προκύπτει ότι το CNN είναι ο μεγάλος νικητής. Ενώ στο θορυβώδες διάστημα των -20 έως -13 (περίπου) dB οι αποδόσεις όλων των ταξινομητών είναι ίδιες, από εκεί και πέρα ο CNN ταξινομητής ξεπερνάει τους υπόλοιπους.




Σχήμα 6.1: Σύγκριση απόδοσης ταξινομητών σε ωμά IQ δείγματα.

Αυτό αποδεικνύει ότι στη περίπτωση των ωμών δεδομένων (raw data), το συνελικτικό νευρωνικό δίκτυο είναι το καλύτερο μέσο ανακάλυψης προτύπων στα δεδομένα. Είναι ο καλύτερος ταξινομητής διαμορφώσεων.

Εξαγωγή ειδικών χαρακτηριστικών

Ενδιαφέρον έχει η παρατήρηση του διαγράμματος στη περίπτωση όπου εξαγάγονται τα ειδικά χαρακτηριστικά του σήματος. Όπως φαίνεται και στο σχήμα 6.2, η συμπεριφορά σε χαμηλό SNR είναι ίδια με το σχήμα 6.1, ενώ μέχρι και τα 5 dB (μεσαίο SNR) νικητής είναι ο CNN. Από εκεί και έπειτα, ο ταξινομητής Boosted Tree είναι ξεκάθαρα ο νικητής.



Σχήμα 6.2: Σύγκριση απόδοσης ταξινομητών με εξαγωγή ειδικών χαρακτηριστικών.

Αυτό ερμηνεύεται ως εξής. Ενώ στα ωμά δείγματα ο CNN κέρδιζε με διαφορά, τώρα που εξήχθησαν τα ειδικά χαρακτηριστικά του σήματος, αυξήθηκε η επίδοση των αλγορίθμων Boosted/Single Tree. Δηλαδή είναι η εξαγωγή των ειδικών χαρακτηριστικών ο λόγος της υπέρσχυσης του αλγορίθμου Boosted Tree (σε υψηλά SNR). Το CNN προσπαθεί να βρει πρότυπα στα δεδομένα χωρίς πρότερη γνώση. Τα ειδικά χαρακτηριστικά αποτελούν αυτή τη πρότερη γνώση, η οποία βοηθά τους αλγορίθμους δένδρων απόφασης, γι' αυτό και υπερισχύουν των CNN.

Αξίζει να σημειωθεί όμως, ότι το νευρωνικό CNN απαλάσσει τον μηχανικό από την χειροκίνητη διαδικασία ανεύρεσης και εξαγωγής των ειδικών χαρακτηριστικών (χρονοβόρα διαδικασία). Τα δέντρα νικάνε μονάχα σε υψηλό θόρυβο και μόνο όταν ο μηχανικός αναλάβει τη δύσκολη διεργασία της εξαγωγής χαρακτηριστικών. **Στις υπόλοιπες περιπτώσεις, νικητής είναι ο ταξινομητής CNN.**


Αν δεν έγινε κατανοητό, να τονιστεί ότι τα ειδικά χαρακτηριστικά **δεν** τα λαμβάνει υπόψη το

CNN. Αυτό βασίζεται **αποκλειστικά** και μόνο στα ωμά δείγματα. Ουσιαστικά από την πρότερη γνώση (των ειδικών χαρακτηριστικών) επωφελούνται μόνο οι αλγόριθμοι Boosted και Single Tree. Άρα, το πείραμα του σχήματος 6.2 είναι εξ αρχής άδικο ως προς το συνελικτικό νευρωνικό δίκτυο! Ακόμη κι έτσι, τα καταφέρνει εξαιρετικά καλά!

6.5.2 Confusion Matrix

Ο πίνακας σύγχυσης (Confusion Matrix) αποτελεί έναν συνοπτικό και γλαφυρό πίνακα για να εξακριβωθεί σε ποιες περιπτώσεις κάνει λάθη το νευρωνικό δίκτυο CNN.

Η διαγώνιος του πίνακα περιλαμβάνει τις περιπτώσεις όπου το CNN μάντεψε σωστά τη διαμόρφωση.



Σχήμα 6.3: Πίνακας Σύγχυσης του CNN (για SNR = 10 dB).

Μάλιστα, παρατηρώντας αναλυτικά το σχήμα 6.3 διαπιστώνεται ότι το μοντέλο μπερδεύει τις διαμορφώσεις QPSK/8PSK, τις διαμορφώσεις WBFM/AM-DSB και τις διαμορφώσεις QAM-16/QAM-64.

- Η διάκριση μεταξύ QAM-16 και QAM-64 είναι δύσκολη διότι οι αστερισμοί τους μοιράζονται πολλά κοινά σημεία, ενώ το παράθυρο παρατήρησης είναι πολύ μικρό (μόνο 128 δείγματα) [29].
- Το QPSK στέλνει τέσσερα σύμβολα χωρίζοντας τον αστερισμό σε τέσσερις φάσεις. το 8PSK στέλνει οχτώ σύμβολα, χρησιμοποιώντας οχτώ φάσεις. Σε καθεστώς θορύβου, οι

περιοχές απόφασης μπερδεύονται μεταξύ τους δημιουργώντας σύγχυση σε ποιον αστερισμό ανήκει το κάθε σύμβολο. Είναι θέμα γεωμετρίας του αστερισμού.

- Η σύγχυση ανάμεσα στις αναλογικές διαμορφώσεις WBFM/AM-DSB εξηγείται ως εξής. Ως αναλογικές διαμορφώσεις, δημιουργήθηκαν χρησιμοποιώντας αποσπάσματα ανθρώπινης ομιλίας (σήμα $m(t)$). Η ανθρώπινη ομιλία έχει παύσεις και κενά ανάμεσα στις λέξεις (σιγή, όταν ο ομιλητής σταματάει να μιλάει: $m(t) = 0$). Στη διαμόρφωση AM-DSB [26, ενότητα 4.2] το σήμα είναι $y(t) = (A_c + m(t))\cos(2\pi f_c t)$, οπότε για $m(t) = 0$ γίνεται $A_c \cos(2\pi f_c t)$. Στο WBFM είναι $y(t) = A_c \cos(2\pi f_c t + 2\pi k_f \int m(\tau) d\tau)$, άρα για $m(t) = 0$ γίνεται και πάλι $A_c \cos(2\pi f_c t)$. Άρα αποδείχθηκε μαθηματικά η αιτία σύγχυσης ανάμεσα σε αυτές τις διαμορφώσεις. Τη στιγμή της σιγής, οι δύο διαμορφώσεις εκπέμπουν ακριβώς το ίδιο αδιαμόρφωτο φέρον σήμα. Το CNN δεν έχει μνήμη για να δει τι ειπώθηκε πριν ή μετά. Βλέπει μόνο το τώρα, δηλαδή σιγή, οπότε δεν μπορεί να ξεχωρίσει τις δύο διαμορφώσεις. Ως μελλοντική εργασία αφήνεται να διαπιστωθεί εάν αυτό λύνεται με χρήση αναδρομικών νευρωνικών δικτύων RNN/LSTM.

Κεφάλαιο 7

Συμπεράσματα και μελλοντική εργασία

Στο τελευταίο αυτό κεφάλαιο ανακεφαλαιώνεται όλη η εργασία και τα πεπραγμένα πειράματα. Μελετήθηκαν μια ευρεία γκάμα τεχνολογιών, από τους Autoencoders, στα Multiple Input - Multiple Output συστήματα, στα δίκτυα Radio Transformer Networks και, τέλος, στα συνελικτικά νευρωνικά δίκτυα CNN.

7.1 Ανακεφαλαίωση επιδόσεων

Ακολουθεί μια σύντομη και περιεκτική ανακεφαλαίωση των αποτελεσμάτων όλων των τεχνολογιών που χρησιμοποιήθηκαν (και που αναφέρονται στην παραπάνω παράγραφο).

End-to-end Autoencoders

Το σύστημα πομπού-κανάλι-δέκτη αναπαραστάθηκε ως αυτοκωδικοποιητής, ο οποίος βελτιστοποίησε ταυτόχρονα πομπό και δέκτη σε μια διαδικασία μη-επιβλεπόμενης μάθησης (unsupervised). Αν και ο Autoencoder(2,4) επέδειξε εφάμιλλη απόδοση (όμως χειρότερη) με τον αστερισμό QAM-16, υστέρησε αρκετά στην περίπτωση της σύγκρισης Autoencoder(7,4) με τον παραδοσιακό κώδικα Hamming(7,4). Ο Autoencoder αποδείχθηκε νικητής σε κανάλι που εισάγει **τυχαία στροφή**

φάσης, όπου νίκησε τον κώδικα Hamming. Αυτό αποδεικνύει ότι η βαθιά μάθηση είναι δυνατή να βρει λύση σε περίπλοκα, άγνωστα περιβάλλοντα, περιβάλλοντα τα οποία δεν είναι φτιαγμένα για τον κώδικα Hamming!

MIMO συστήματα

Στα συστήματα πολλών εισόδων-πολλών εξόδων, η χρήση δυναμικών βαρών, όπως προκύπτει από την εξίσωση 4.1, επέφερε ισότητα στην επίδοση BLER των δύο χρηστών του συστήματος, όπως φαίνεται στο σχήμα 4.6. Επιπλέον, οι Autoencoders υπερτέρησαν έναντι της διαμόρφωσης $2^{2k/n}$ -QAM Time Sharing (TS) (σχήμα 4.7).

Radio Transformer Networks

Τα RTN δίκτυα ενσωματώνουν την ειδική γνώση (domain expert knowledge). Αυτό έχει ως αποτέλεσμα τα δίκτυα RTN να προσφέρουν καλύτερη ισοστάθμιση σε πολυδιαδρομικά κανάλια με διαλείψεις Rayleigh από την διαμόρφωση differential BPSK (DBPSK) με εκτιμητή μέγιστης πιθανοφάνειας (MLE) και κώδικα Hamming(7,4). Μια βασική διαπίστωση είναι ότι όταν τα νευρωνικά δίκτυα των Autoencoders (δηλαδή του encoder και του decoder) κατασκευάζονται πλατύτερα και εκπαιδεύονται για περισσότερες εποχές, τότε η διαφορά στην απόδοσή των μειώνεται!

Convolutional Neural Networks

Τα συνελικτικά νευρωνικά δίκτυα είναι ειδικά στην αναγνώριση εικόνας και την υπολογιστική όραση (computer vision). Όμως επιδεικνύουν σημαντικές επιδόσεις και στις τηλεπικοινωνίες, όπου κατάφεραν να ταξινομήσουν τις διαμορφώσεις με χρήση αποκλειστικά ωμών (raw) IQ δειγμάτων. Συγκρίθηκε ένα συνελικτικό νευρωνικό με τους αλγόριθμους Single Tree και Boosted Tree. Στα ωμά δείγματα νίκησε σαφώς το CNN, ενώ στη περίπτωση χρήσης ειδικών χαρακτηριστικών (στατιστικά μεγέθη όπως ασυμμετρία κ.α.) ο νικητής είναι ο αλγόριθμος Boosted Tree (μετά τα 5 dB, σχήμα 6.2).

7.2 Αξιοσημείωτα συμπεράσματα

Deep Learning εναντίον παραδοσιακής τηλεπικοινωνιακής θεωρίας

Οι παραδοσιακοί αλγόριθμοι όπως ο κώδικας Hamming είναι βέλτιστος για ιδανικά κανάλια με γνωστό μαθηματικό μοντέλο (περιβάλλοντα AWGN). Το πλεονέκτημα της Βαθιάς Μάθησης είναι ότι προσαρμόζεται δυναμικά σε άγνωστα περιβάλλοντα, με μη-γραμμικότητες και ατέλειες, όπως άγνωστη στροφή φάσης, παρεμβολές, διαλείψεις.

Εξαγωγή χαρακτηριστικών

Η εξαγωγή χαρακτηριστικών έδωσε τη νίκη στον αλγόριθμο Boosted Tree σε SNR μεγαλύτερα των 5 dB. Όμως σε όλη την περιοχή από -13 έως 5 dB ο απόλυτος νικητής είναι το CNN. Αυτό σημαίνει ότι για ένα μεγάλο εύρος SNR, είτε χρησιμοποιηθούν ειδικά χαρακτηριστικά, είτε όχι, νικητής είναι το CNN. Επίσης η εξαγωγή χαρακτηριστικών είναι **χρονοβόρα και χειροκίνητη διαδικασία**. Για αυτούς τους δύο λόγους λοιπόν, η χρήση συνελκτικού νευρωνικού δικτύου απευθείας πάνω στα ωμά δείγματα έχει το απόλυτο πλεονέκτημα.

7.3 Περιορισμοί και προτάσεις για περαιτέρω έρευνα

Ενσωμάτωση μνήμης

Όπως φάνηκε στον πίνακα σύγκρισης της ενότητας 6, η σύγκριση στην αναγνώριση των διαμορφώσεων QAM-16/QAM-64, QPSK/8-PSK, WBFM/AM-DSB οφείλεται στο μικρό παράθυρο παρατήρησης (μόνο 128 δείγματα). Τα CNN δίκτυα **στερούνται μνήμης**, για να αναλύσουν το σήμα πριν και μετά την σιγή ή την παύση. Μένει να διαπιστωθεί εάν η χρήση νευρωνικών δικτύων με μνήμη, δηλαδή αναδρομικών νευρωνικών δικτύων RNN/LSTM προσφέρει ή όχι λύση σε αυτό το πρόβλημα.

Πραγματικό hardware vs προσομοίωση

Τα πειράματα έγιναν όλα σε περιβάλλον προσομοίωσης στον υπολογιστή, αν και το dataset [32] προήλθε από πραγματικά πειράματα. Εντούτοις, ο υπολογιστής δεν μπορεί να προσομοιώσει ε-

πακριβώς τις ατέλειες του πραγματικού hardware (π.χ. ψαλιδισμός από ενισχυτές ισχύος). Σε μελλοντικό στάδιο αξίζει να εκτελεστεί το πείραμα σε πραγματικές συσκευές software defined radio (SDR) και να διερευνηθούν οι επιπτώσεις των μη-γραμμικοτήτων του ενισχυτή ισχύος.

7.4 Επίλογος

Η εργασία είχε ως κύριο στόχο την χρήση βαθιάς μάθησης στα συστήματα επικοινωνίας. Μελετήθηκε η μετάβαση από την παραδοσιακή θεώρηση των συστημάτων επικοινωνίας στην υλοποίησή τους από άκρο σε άκρο με χρήση αυτοκωδικοποιητών, οι οποίοι θα εκπαιδεύονται χωρίς πρότερη γνώση. Η χρήση αυτοκωδικοποιητών προσφέρει σημαντικά πλεονεκτήματα, ειδικά εκεί όπου οι παραδοσιακοί αλγόριθμοι και κώδικες αποτυγχάνουν, όπως στην **επινόηση** διαμορφώσεων σε περιβάλλοντα έντονου θορύβου και μη γραμμικοτήτων. Όσο ωριμάζει η χρήση βαθιάς μάθησης στις τηλεπικοινωνίες, πιστεύεται ότι τα πλεονεκτήματα θα πληθύνουν και -γιατί όχι- τα συστήματα επικοινωνίας θα αντικατασταθούν από αλγορίθμους τεχνητής νοημοσύνης.

Βιβλιογραφία

- [1] GeeksforGeeks, “Convolutional neural network (CNN) in machine learning.” <https://www.geeksforgeeks.org/deep-learning/convolutional-neural-network-cnn-in-machine-learning/>. Accessed: June 2026.
- [2] M. Lichtman, “Channel coding - PySDR: A guide to SDR and DSP using python.” https://pysdr.org/content/channel_coding.html. Accessed: June 2026.
- [3] S. Russell and P. Norvig, “Artificial intelligence: A modern approach, 4th global ed,” *Harlow, UK: Pearson Education Limited*, 2022.
- [4] Κωνσταντίνος Διαμαντάρας και Δημήτρης Μπότσης, *Μηχανική Μάθηση*. Εκδόσεις Κλειδάριθμος, 2019.
- [5] I. Goodfellow, Y. Bengio, and A. Courville, *Deep Learning*. MIT Press, 2016. <http://www.deeplearningbook.org>.
- [6] S. Haykin, *Neural networks and learning machines, 3/E*. Pearson education india, 2009.
- [7] L. Bottou, “Large-scale machine learning with stochastic gradient descent,” in *Proceedings of COMPSTAT’2010: 19th International Conference on Computational Statistics Paris France, August 22-27, 2010 Keynote, Invited and Contributed Papers*, pp. 177–186, Springer, 2010.
- [8] D. P. Kingma and J. Ba, “Adam: A method for stochastic optimization,” *arXiv preprint arXiv:1412.6980*, 2014.

- [9] S. Ruder, “An overview of gradient descent optimization algorithms,” *arXiv preprint arXiv:1609.04747*, 2016.
- [10] Y. LeCun, Y. Bengio, and G. Hinton, “Deep learning,” *nature*, vol. 521, no. 7553, pp. 436–444, 2015.
- [11] A. Krizhevsky, I. Sutskever, and G. E. Hinton, “Imagenet classification with deep convolutional neural networks,” *Advances in neural information processing systems*, vol. 25, 2012.
- [12] S. Scott, “Autoencoders (lecture slides).” <https://cse.unl.edu/~sscott/teach/Classes/cse496S18/slides/5-Autoencoders.pdf>, 2018. University of Nebraska-Lincoln. Accessed: June 2026.
- [13] G. E. Hinton and R. R. Salakhutdinov, “Reducing the dimensionality of data with neural networks,” *science*, vol. 313, no. 5786, pp. 504–507, 2006.
- [14] D. Bank, N. Koenigstein, and R. Giryes, “Autoencoders,” *Machine learning for data science handbook: data mining and knowledge discovery handbook*, pp. 353–374, 2023.
- [15] T. O’shea and J. Hoydis, “An introduction to deep learning for the physical layer,” *IEEE Transactions on Cognitive Communications and Networking*, vol. 3, no. 4, pp. 563–575, 2017.
- [16] S. Dörner, S. Cammerer, J. Hoydis, and S. Ten Brink, “Deep learning based communication over the air,” *IEEE Journal of Selected Topics in Signal Processing*, vol. 12, no. 1, pp. 132–143, 2017.
- [17] C. E. Shannon, “A mathematical theory of communication,” *The Bell system technical journal*, vol. 27, no. 3, pp. 379–423, 1948.
- [18] J. G. Proakis and M. Salehi, *Digital communications*, vol. 4. McGraw-hill New York, 2001.
- [19] S. Lin, “D. costello error control coding,” 2004.

- [20] D. Tse and P. Viswanath, *Fundamentals of wireless communication*. Cambridge university press, 2005.
- [21] T. S. Rappaport, “Wireless communications—principles and practice, (the book end).,” *Microwave Journal*, vol. 45, no. 12, pp. 128–129, 2002.
- [22] T. Cover, “Broadcast channels,” *IEEE Transactions on Information Theory*, vol. 18, no. 1, pp. 2–14, 1972.
- [23] T. J. O’Shea, K. Karra, and T. C. Clancy, “Learning to communicate: Channel auto-encoders, domain specific regularizers, and attention,” in *2016 IEEE International Symposium on Signal Processing and Information Technology (ISSPIT)*, pp. 223–228, IEEE, 2016.
- [24] M. Jaderberg, K. Simonyan, A. Zisserman, *et al.*, “Spatial transformer networks,” *Advances in neural information processing systems*, vol. 28, 2015.
- [25] L. von Rueden, S. Mayer, K. Beckh, B. Georgiev, S. Giesselbach, R. Heese, B. Kirsch, M. Walczak, J. Pfrommer, A. Pick, R. Ramamurthy, J. Garcke, C. Bauckhage, and J. Schuecker, “Informed machine learning - a taxonomy and survey of integrating prior knowledge into learning systems,” *IEEE Transactions on Knowledge and Data Engineering*, p. 1–1, 2021.
- [26] Γεώργιος Καραγιαννίδης και Κοραλία Παππή, *Τηλεπικοινωνιακά Συστήματα*, 4η Έκδοση. Εκδόσεις Τζιόλας, 2017.
- [27] B. Sklar, “Rayleigh fading channels in mobile digital communication systems. i. characterization,” *IEEE Communications magazine*, vol. 35, no. 7, pp. 90–100, 1997.
- [28] L. Van der Maaten and G. Hinton, “Visualizing data using t-sne,” *Journal of machine learning research*, vol. 9, no. 11, 2008.
- [29] T. J. O’Shea, J. Corgan, and T. C. Clancy, “Convolutional radio modulation recognition networks,” in *International conference on engineering applications of neural networks*, pp. 213–226, Springer, 2016.

- [30] A. Swami and B. M. Sadler, “Hierarchical digital modulation classification using cumulants,” *IEEE Transactions on communications*, vol. 48, no. 3, pp. 416–429, 2000.
- [31] O. A. Dobre, A. Abdi, Y. Bar-Ness, and W. Su, “Survey of automatic modulation classification techniques: classical approaches and new trends,” *IET communications*, vol. 1, no. 2, pp. 137–156, 2007.
- [32] DeepSig Inc., “Radioml 2016.10a.” <https://www.deepsig.ai/datasets/>, 2016. Accessed: June 2026.
- [33] F. Pedregosa, G. Varoquaux, A. Gramfort, V. Michel, B. Thirion, O. Grisel, M. Blondel, P. Prettenhofer, R. Weiss, V. Dubourg, *et al.*, “Scikit-learn: Machine learning in python,” *the Journal of machine Learning research*, vol. 12, pp. 2825–2830, 2011.
- [34] T. Chen and C. Guestrin, “Xgboost: A scalable tree boosting system,” in *Proceedings of the 22nd acm sigkdd international conference on knowledge discovery and data mining*, pp. 785–794, 2016.